

Калиброванная навигация по ненадёжной открытословарной семантической карте: совместный учёт ошибок метки и позы

Calibrated Navigation over Unreliable Open-Vocabulary Semantic Maps: Joint Label and Pose Error

Щетинкин Сергей Олегович

магистратура ИТМО «Робототехника и искусственный интеллект», 1 курс

Тестовое задание лаборатории BE2R, направление «Семантическое картирование, визуальная привязка
и навигация»

октябрь 2026 · код и данные: <https://github.com/byoverr/calibrated-semantic-nav>

Аннотация

Планировщик, который едет по открытословарной семантической карте, получает ошибки из двух источников: неверные или неполные метки детектора и дрейф оценки позы. Известные статистические гарантии для планирования по картам восприятия предполагают, что поза робота известна. В работе предложено калибровать одну величину — *расстояние промаха*, на которое истинный объект запретного класса выходит за область этого класса на карте, построенной по оценённым позам, — конформным предсказанием по сценам. Получаемый радиус запаса покрывает оба источника ошибки и даёт гарантию для любого планировщика. На 22 сценах OSMa-Bench (ReplicaCAD; детектор YOLO-World, синтетический дрейф позы шести уровней, 200 разбиений сцен, $\alpha = 0,1$) показано: (1) карта без калибровки почти никогда не покрывает объект целиком, и планировщик нарушает безопасное расстояние в 27–37 % путей; (2) покадровая калибровка меток вырождается и теряет покрытие уже при 2 см дрейфа (медианный ATE) ($1,00 \rightarrow 0,73$ для велосипеда), калибровка только по меткам — при 45 см (0,76), калибровка только по позе недопокрывает при любом реалистичном дрейфе; (3) совместная калибровка держит покрытие 0,93–0,94 на всех уровнях и даёт радиус на 27 % меньше суммы отдельных (на L4), в миссиях — ноль нарушений; (4) цена гарантии — запретная зона около 1,3 м, при которой путь находится лишь в ≈ 30 % задач против 98 % у планировщика по истинной карте, а для тумбы под ТВ, которую детектор в 2 сценах из 21 уверенно принимает за другой класс, честная калибровка отказывается давать гарантию; повышение α до 0,3 почти не добавляет решаемости — упор в ошибку восприятия; (5) mIoU карты не предсказывает безопасность миссии ($\rho = -0,16$). В условиях ближайшей работы (известная поза, закрытый словарь, 95 %, случайные задачи) её покадровая калибровка меток и предложенная дают одинаковый успех миссий (0,43 и 0,42); при дрейфе 2–7 см её покрытие падает до 0,42–0,10, а предложенная держит 0,94 и успешнее (0,61–0,50 против 0,40–0,32); с открытым словарём предложенная даёт в 1,8 раза больше успешных миссий (0,78 против 0,43), потому что калибровка меток вырождается в «запретно всё занято» при любом шаге сетки. Три упрощения проверены отдельно. Маски MobileSAM снимают ошибку меток в типичной сцене, но не наихудшую, которая и задаёт радиус при 13 калибровочных сценах. Реальная RGB-D одометрия без замыканий циклов (медианный ATE 78 см) ломает калибровку только по меткам (покрытие 0,67), а совместная калибровка остаётся валидной, но в большинстве разбиений честно отказывается. В стресс-тесте с редкими отказами локализации, разнесёнными по сценам, сумма отдельных квантилей недопокрывает (0,66 при номинале 0,70), совместная — нет. На сценах HM3D, откалиброванных по ReplicaCAD, гарантия не переносится. Предварительно показано, что на ужесточённых картах угловая зона выборки двунаправленного RRT требует в 2,3–3 раза больше расширений, чем равномерная выборка, а предложенное адаптивное расширение зоны сокращает разницу до 1,2–1,4 раза, не удлиняя первые пути — это задача для ВКР по планированию движения.

1. Задача и мотивация

Открытословарные семантические карты (ConceptGraphs [1], BBQ, OpenScene) позволяют роботу искать объекты и избегать их по произвольному текстовому запросу: «не подъезжай к растению», «держись дальше от велосипеда». Такая карта собирается из двух ненадёжных источников. Метки дают детектор или сегментатор открытого словаря, и они ошибаются. Положение объектов задаётся оценкой позы робота (SLAM, одометрия), и она дрейфует. Планировщик же обычно считает карту правдой: ищет путь по предсказанным областям классов и держит до них фиксированный зазор.

Цена такого допущения не измеряется. Бенчмарк лаборатории BE2R OSMa-Bench [2] показывает, что качество открытословарных карт сильно деградирует: при динамическом освещении f-mIoU

ConceptGraphs падает с 28,00 до 14,29 (табл. I в [2]). Но бенчмарк оценивает карту как изображение, без задачи движения. Обзор 3D-графов сцены 2026 г. [3] формулирует то же в общем виде: влияние ошибок восприятия на поведение робота почти никогда не измеряют напрямую.

Есть и работы, которые дают планировщику статистическую гарантию поверх ненадёжного восприятия, с помощью конформного предсказания (conformal prediction, CP). Sundarsingh и др. [4] калибруют множества меток клеток семантической карты, а Perceive With Confidence [5] калибрует раздувание карты занятости. Обе работы явно предполагают, что *поза робота известна*. Работа о композиции гарантий [6] показывает, что раздельно откалиброванные модули не дают откалиброванной системы.

Задача работы — измерить, как совместные ошибки метки и позы проходят в нарушения безопасности при навигации по открытословарной карте, и проверить, может ли *одна* калиброванная величина — «расстояние промаха» — дать планировщику гарантию сразу на оба источника ошибки.

Работа выполнена как тестовое задание лаборатории BE2R (направление «семантическое картирование, визуальная привязка и навигация») и одновременно как первый шаг ВКР по планированию движения в условиях неопределённости (научный руководитель И. С. Довгополик). Карта и её ошибки здесь — источник неопределённости, а предмет работы — решение планировщика: куда можно ехать и с каким запасом.

2. Анализ работ

Работы отобраны по трём вопросам: как карта выражает свою ненадёжность, как планировщик получает гарантию и что происходит с картой при ошибке позы. Все числа ниже взяты из полных текстов (раздел или таблица указаны); площадки подтверждены по DOI или официальной программе, препринты отмечены.

Открытословарные карты и их деградация

ConceptGraphs [1] (ICRA 2024) строит из RGB-D-последовательности 3D-граф объектов: маски сегментатора объединяются между кадрами, каждому объекту ставится в соответствие эмбединг CLIP, метка — аргмаксимум косинусного сходства с текстовым запросом. Это де-факто стандарт открытословарного картирования. *Ограничение для навигации*: карта не выдаёт никакой меры уверенности, а аргмаксимум не откалиброван.

OSMa-Bench [2] (BE2R, IROS 2025) оценивает ConceptGraphs, BBQ и OpenScene на симулированных сценах ReplicaCAD и HM3D при разных условиях освещения; метрики — mAcc, f-mIoU и ответы на вопросы по графу сцены. Главный результат — сильная деградация при смене освещения (f-mIoU ConceptGraphs 28,00 → 14,29). *Ограничение*: бенчмарк не содержит задачи движения, поэтому не говорит, как деградация карты отражается на роботе. *Наблюдение при воспроизведении*: в опубликованном наборе на HuggingFace для каждой сцены есть только одно условие освещения (baseline для 22 сцен ReplicaCAD, no_lights для 8 сцен HM3D), хотя карточка набора обещает четыре; остальные условия воспроизводятся только генератором HaDaGe на GPU.

OSMa-Bench++ [7] (BE2R, воркшоп ICRA 2026) расширяет протокол на 40 сгенерированных по текстовым описаниям сцен (160 последовательностей, четыре конфигурации освещения) с уклоном в манипуляцию: мелкие объекты, отношения «на», «внутри». На 3 октября 2026 г. данные не опубликованы (ссылка на HuggingFace на странице проекта — заглушка).

On the Overconfidence Problem in Semantic 3D Mapping [8] (ICRA 2024): наивное байесовское слияние кадровых вероятностей делает карту переуверенной — средняя ошибка калибровки mECE вокселей 0,451 против 0,124 у пикселей (табл. I); усреднение калибрует лучше. Отсюда в нашей карте — слияние усреднением.

Гарантии для планировщика

Конформное предсказание пришло в планирование через прогноз движения агентов: Lindemann и др. [15] калибруют ошибку прогноза траекторий и превращают её в запас безопасности планировщика. Ниже — работы, где калибруется само восприятие.

Sundarsingh и др. [4] (RA-L 2026) — ближайшая работа: семантическая карта с конформно откалиброванными множествами меток клеток и планировщик, обходящий клетки, которые *могут* принадлежать запретному классу. Калибровочная единица — среда (50 калибровочных, 61 тестовая). При

$1 - \alpha = 95\%$ доля корректных карт $93,36 \pm 3,19\%$, успех миссий $98,36 \pm 1,63\%$ (табл. I). *Ограничения:* поза явно считается известной (разд. II), классов пять (закрытый словарь), сетка 1 м; при сдвиге условий покрытие падает с 90,16 до 80,33 % при номинале 90 % (разд. V-F); в будущей работе авторы называют прямую оценку неопределённости сенсоров.

Perceive With Confidence [5] (IJRR 2025) калибрует *минимальное раздувание* карты занятости, при котором она накрывает истинные препятствия; гарантия не зависит от планировщика. В симуляции 400 калибровочных сред дают при $\varepsilon = 0,15$ порог 0,75 м. *Ограничения:* только геометрия, без семантики; состояние робота считается известным (разд. VI). Наш счёт «расстояние промаха» — семантический аналог этого счёта.

Learnable CP [9] (ICRA 2026) калибрует зазор RRT* по выученному из 20 геометрических признаков счёту; среди деградаций есть синтетический дрейф локализации ($\sigma = 0,5$ м). *Ограничения:* семантики нет, калибровка одна на все среды и виды шума, покрытие — по точкам пути, а не по задаче.

Conformal Constraint Tightening [10] (препринт 2026, группа Kantaros) калибрует наихудшее отклонение и ужесточает ограничения так, что *любой* план, решающий ужесточённую задачу, безопасен с вероятностью не ниже $1 - \alpha$; показано, что доля задач, решаемых RRT, падает с ростом ужесточения. Это прямо задаёт место планировщика: гарантию даёт калибровка, а от планировщика зависит, решит ли он суженную задачу.

Композиция гарантий и ошибка позы

Marginal Calibration Does Not Compose [6] (воркшоп IROS 2026): два модуля, каждый с покрытием 95 %, после композиции дают от 86,46 до 99,98 % в зависимости от корреляции ошибок; при положительной корреляции — 39,7 столкновения против 8,7 на 10 000 прогонов; совместная калибровка возвращает 95,18–95,25 % (разд. V, гауссов пример).

P-POSEMEM [11] (препринт 2026) — семантическая память, согласованная с перестройкой графа поз SLAM. На реальном роботе замыкания циклов сдвигают ключевые кадры на 2–11 м (медиана), объект с координатой, замороженной при вставке, оказывается в 2,75 м от себя, «переключение цели» происходит в 18 % запросов; при этом номинальный 95 %-эллипсоид позы покрывает лишь 33 % реальных ошибок. Ошибка позы в семантической навигации — реальная и плохо откалиброванная.

Сводка

Таблица 1: Кто что калибрует и при каком допущении о позе

Работа	Что калибруется	Поза	Планировщик в контуре
Sundarsingh [4]	множества меток клеток (закрытый словарь)	известна	да
PwC [5]	раздувание карты занятости	известна	да (любой безопасный)
Learnable CP [9]	геометрический зазор по признакам	синтетический сдвиг	да (RRT*)
Tightening [10]	отклонение исполнения	—	да (любой)
P-POSEMEM [11]	— (байесовская память)	распределение, некалибровано	цели, без гарантии
Эта работа	расстояние промаха: метка + поза	оценка с дрейфом	да

Пустая клетка таблицы 1 — одна distribution-free гарантия на ошибку метки открытого словаря и ошибку позы, проверенная с планировщиком в контуре. По цитированиям ближайших работ и поиску по arXiv и OpenAlex (2 октября 2026 г.) такой работы не найдено; поиск Semantic Scholar по ключевым словам в эти дни не работал, поэтому вывод о новизне предварительный.

3. Постановка и гипотезы

Дано

Сцены $\Omega_1, \dots, \Omega_n, \Omega_{\text{test}}$ обмениваемы. В сцене робот проходит траекторию с истинными позами $T_k \in SE(3)$ и оценёнными позами $\hat{T}_k = D_k T_k$, где D_k — накопленная к кадру k ошибка оценщика позы (плоская: сдвиг по полу и поворот вокруг вертикали). Карта $\hat{M}$ строится по кадрам, размещённым по оценённым позам; клетка j хранит долю наблюдений $p_j(k)$, поддерживающих класс k . Область класса на карте при пороге λ :

$$A_\lambda(k) = \{j : j \text{ занята}, p_j(k) \geq \lambda\}. \quad (3.1)$$

Планировщик действует в системе координат, в которой робот считает себя находящимся в момент запроса q . Истинный след объекта e класса k_e в этой системе — $\hat{F}(e) = D_q F(e)$: объект, увиденный в кадре k , лежит на карте по D_k , а на самом деле — по D_q , поэтому карта ошибается и из-за метки, и из-за дрейфа, накопленного между наблюдением и запросом.

Счёт и гарантия

Расстояние промаха класса k в сцене Ω :

$$s_k(\Omega) = \min \left\{ R_{\max}, \max_{e: k_e=k} \max_{x \in \hat{F}(e)} \text{dist}(x, A_\lambda(k)) \right\}. \quad (3.2)$$

Неверная метка (объект не попал в $A_\lambda(k)$) даёт большой промах, сдвиг из-за позы — промах на величину сдвига; поэтому одна величина поглощает оба источника ошибки. Порог $\hat{q}_k$ — порядковая статистика с номером $\lceil (n+1)(1-\alpha) \rceil$ среди $s_k(\Omega_1), \dots, s_k(\Omega_n)$ (split conformal prediction [14]). При обменности сцен

$$P\left(\hat{F}(e) \subseteq A_\lambda(k) \oplus B(\hat{q}_k) \quad \forall e : k_e = k\right) \geq 1 - \alpha, \quad (3.3)$$

маргинально по калибровочным и тестовой сценам. Если планировщик держит $\text{dist}(x, A_\lambda(k)) \geq d + \hat{q}_k$, то по неравенству треугольника истинное расстояние до любого объекта класса k не меньше d . Гарантия не зависит от планировщика; от планировщика зависит, найдёт ли он путь в суженном свободном пространстве. Если $\hat{q}_k \geq R_{\max}$ или $n < 1/\alpha - 1$, ветка *отказывается* от гарантии — сертификат пуст, что формально верно, но бесполезно.

Один счёт на сцену, а не на клетку или кадр, выбран сознательно: клетки и кадры одной сцены сильно коррелированы, и их пулинг нарушает обменность.

Сравниваемые ветки

Все ветки, кроме справочной, используют одну и ту же область $A_{\lambda_0}(k)$ и отличаются тем, на чём калибруется радиус:

- **без калибровки**: радиус 0, карта принимается как есть;
- **только метки**: промах карты при истинных позах (ошибка восприятия без дрейфа);
- **только поза**: промах карты с *эталонными* метками, построенной по позам с дрейфом;
- **раздельно**: сумма двух радиусов выше, каждый на уровне α (наивная композиция);
- **совместно** (эта работа): один квантиль промаха карты детектора, построенной по позам с дрейфом;
- справочная **покадровая СР меток** в духе [4]: порог $\lambda^* = 1 - \hat{q}$ по счёту $1 - p_j(k)$ на клетках истинного следа, без раздувания.

Деление «по Бонферрони» ($\alpha/2 + \alpha/2$) при $\alpha = 0,1$ требует не меньше 19 калибровочных сцен и при наших 9 неприменимо — это само по себе практическое ограничение раздельной калибровки.

Гипотезы

- H1. Калибровка, учитывающая только ошибку меток, теряет покрытие при дрейфе позы.
- H2. Калибровка, учитывающая только позу, недопокрывает из-за ошибок меток.
- H3. Совместная калибровка держит заданное покрытие при всех уровнях дрейфа и даёт меньший запас, чем сумма раздельных радиусов.
- H4. Метрика качества карты (mIoU) плохо предсказывает безопасность миссии.

Н5. Ужесточение ограничений сужает свободное пространство, и решаемость задачи выборочным планировщиком за фиксированный бюджет падает — здесь и определяется вклад планировщика.

4. Экспериментальная установка

Данные. OSMa-Bench [2], часть ReplicaCAD [13] (лицензия CC BY 4.0): RGB, глубина, эталонная семантика (102 класса) и позы камеры для каждого кадра, 640×480 , освещение *baseline*. Берётся каждый 8-й кадр (≈ 205 кадров на сцену). Сцена *apt_0* — dev-сцена: на ней приняты все решения по дизайну, в калибровку и тест она не входит; остальные 21 сцена — калибровка и тест. Позы *traj.txt* — матрица «камера → мир» с осями OpenCV; это проверено совмещением облаков соседних кадров (медианное расстояние 2,1 см против 21,4 и 12,7 см для альтернативных конвенций).

Восприятие. YOLO-World v2-s [12] с 98 текстовыми запросами — словарь ReplicaCAD без структурных классов (*other*, *floor*, *wall*, *ceiling*). Рамка переводится в пиксели по согласованности глубины: берутся пиксели в пределах 0,25 м от медианной глубины рамки. На Apple M (MPS) детекция занимает 24 мс на кадр. Пиксели проецируются в 2D-сетку 5 см; в клетке накапливается доля наблюдений с уверенностью каждого класса (слияние усреднением [8]). Занятость — точки на высоте 0,1–1,8 м, пол — ниже 5 см.

Запретные классы. *indoor_plant*, *tv_stand*, *bike* — хрупкие или дорогие объекты, присутствующие во всех сценах. Класс *stair* исключён по dev-сцене: это область 5 м^2 , а не объект, и рамочный детектор её не локализует. Порог области $\lambda_0 = 0,05$ выбран на dev-сцене по минимальной площади запретной зоны (плато 0,05–0,10; при $\lambda = 0$, т. е. «всё занято запретно», зона занимает 79 % свободного пространства против 27 %).

Дрейф позы. Одометрическая модель: каждое относительное движение истинной траектории повторяется с шумом, пропорциональным шагу (сдвиг по полу и рысканье), как в моделях движения одометрии. Камеры ReplicaCAD горизонтальны (проверено), поэтому высота, крен и тангаж точны. Уровни заданы один раз на dev-сцене (путь 33,7 м) по целевым ATE из публикаций и применяются ко всем сценам без изменений, так как шум задан на метр пути и градус поворота, т. е. это свойство оценщика, а не сцены. Ниже — медианный ATE на 21 оценочной сцене (пути там короче, чем на dev-сцене): L1 — 0,4 см (плотный RGB-D SLAM на синтетике), L2 — 2 см (реальный RGB-D SLAM), L3 — 7 см (трудные сцены), L4 — 45 см (3,6 % пути, одометрия без замыканий), L5 — 2,7 м (21 % пути, стресс-тест). На каждый уровень — 10 реализаций.

Калибровка. $\alpha = 0,1$; 200 случайных разбиений 21 сцены на 13 калибровочных и 8 тестовых; калибровочная сцена даёт одну случайную реализацию дрейфа, тестовые — все. $R_{\max} = 3$ м. Отказ ветки считается выполненной (пустой) гарантией и учитывается отдельно.

Миссии. Задачи «проезд мимо»: старт и цель на полу не ближе 1,5 м к запретным объектам и не ближе 3 м друг к другу, причём кратчайший путь по одной лишь геометрии проходит ближе 0,5 м к запретному объекту; безопасный объезд существует. Цель задана геометрически, чтобы ошибки семантики целей не смешивались с изучаемой гарантией. План — кратчайший путь (Дейкстра на 8-связной сетке) по карте детектора; радиус робота 0,2 м, безопасное расстояние до запретных объектов $d = 0,5$ м плюс радиус ветки. Параметры веток для сцены калибруются на всех *остальных* сценах (*leave-one-scene-out*). Класс, для которого ветка отказывается, переходит на геометрический запасной вариант: запретным считается всё занятое, раздутое на радиус «только поза». Основная конфигурация — запретные классы растение и велосипед; системная — все три. Результат оценивается по истинной геометрии в системе координат планировщика: нарушение — путь ближе d к истинному запретному объекту, столкновение — ближе радиуса робота к истинному препятствию; «оракул» планирует по истинной карте. На каждый уровень дрейфа — 5 реализаций.

Мост к планировщику ВКР. Для уровня L2 запретные зоны совместной ветки масштабируются коэффициентом $m \in \{0; 0,5; 1; 1,5\}$; на решаемых (по Дейкстре) задачах сравниваются RRT-Connect, вариант с угловой динамической зоной выборки двунаправленного RRT научного руководителя (начальный угол 8° , шаг 2° , доля конусных образцов 0,7) и его модификация с расширением конуса по заблокированным расширениям дерева; бюджет 1500 расширений, 2 запуска на задачу с общими случайными числами.

Вся обработка выполнена на MacBook (Apple Silicon) без GPU NVIDIA; данные — около 0,2 ГБ.

5. Результаты

5.1. Покрытие гарантий при дрейфе позы

Таблица 2 и рис. 1 показывают безусловное покрытие (отказ ветки засчитывается как выполненная пустая гарантия) и медианный радиус $\hat{q}$ по 200 разбиениям; 21 сцена, 13 калибровочных, $\alpha = 0,1$.

Таблица 2: Покрытие истинных следов объектов и радиус запаса (медиана). «отк.» — доля разбиений, в которых ветка отказалась (радиус не меньше $R_{\max}$)

Класс	Ветка	L0		L2		L3		L4	
		покр.	$\hat{q}$, м	покр.	$\hat{q}$, м	покр.	$\hat{q}$, м	покр.	$\hat{q}$, м
велосипед	без калибровки	0,00	0	0,00	0	0,01	0	0,01	0
	покадровая СР меток	1,00	0	0,73	0	0,34	0	0,17	0
	только метки	0,93	0,75	0,94	0,75	0,93	0,75	0,76	0,75
	только поза	0,00	0,00	0,03	0,07	0,22	0,18	0,82	0,90
	раздельно (сумма)	0,93	0,75	0,98	0,82	0,99	0,90	0,97	1,61
	совместно	0,93	0,75	0,94	0,75	0,94	0,75	0,93	1,18
растение	без калибровки	0,00	0	0,00	0	0,00	0	0,00	0
	покадровая СР меток	1,00	0	0,41	0	0,10	0	0,03	0
	только метки	0,93	отк. 0,63	0,96	отк. 0,64	0,94	отк. 0,64	0,86	отк. 0,64
	только поза	0,00	0,00	0,00	0,11	0,13	0,25	0,86	1,39
	раздельно (сумма)	0,93	отк. 0,63	0,98	отк. 0,64	0,96	отк. 0,64	0,95	отк. 0,64
	совместно	0,93	отк. 0,63	0,93	0,80	0,94	отк. 0,55	0,93	отк. 0,58
тумба под ТВ	без калибровки	0,05	0	0,01	0	0,00	0	0,00	0
	покадровая СР меток	1,00	0	0,77	0	0,61	0	0,30	0
	только метки	0,98	отк. 0,95	0,98	отк. 0,95	0,98	отк. 0,95	0,99	отк. 0,95
	только поза	0,05	0,00	0,06	0,07	0,13	0,16	0,47	0,56
	раздельно (сумма)	0,98	отк. 0,95	0,98	отк. 0,95	0,98	отк. 0,95	1,00	отк. 0,95
	совместно	0,98	отк. 0,95	0,98	отк. 0,94	0,97	отк. 0,93	0,94	отк. 0,72




Рис. 1: Покрытие (верхний ряд), радиус запаса (средний) и доля отказов (нижний) по классам и уровням дрейфа

Велосипед — класс, который детектор находит надёжно, поэтому на нём эффекты видны в чистом виде.

- *Без калибровки* карта почти никогда не накрывает истинный след объекта целиком (покрытие $\leq 0,01$ на L0–L4): детектор помечает объект с недобором по краям.
- *Покадровая CP меток* в духе [4] без дрейфа даёт покрытие 1,00 — но ценой порога $\lambda^* \approx 0$, при котором запретной считается любая занятая клетка. При дрейфе покрытие падает: 0,73 на L2 (2 см), 0,34 на L3, 0,17 на L4.
- *Только метки* (радиус 0,75 м, откалиброван без дрейфа) держит покрытие на L1–L3 (0,93–0,94): при реалистичной ошибке SLAM до 7 см ошибка меток доминирует. На L4 (45 см) покрытие падает до 0,76, на L5 — до 0,42. Гипотеза H1 подтверждается, но только когда дрейф сравним с радиусом ошибки меток.
- *Только поза* недопокрывает при любом уровне ниже L4 (0,00–0,22): радиус, откалиброванный по эталонным меткам, не видит ошибок детектора. Гипотеза H2 подтверждается.
- *Раздельно* (сумма двух радиусов) валидна, но перестраховывается: покрытие 0,97–0,99 при номинале 0,9, радиус на L4 — 1,61 м.
- *Совместно* держит покрытие 0,93–0,94 на L0–L4 с радиусом 0,75 м на L0–L3 и 1,18 м на L4 — на 27 % меньше суммы раздельных. Гипотеза H3 подтверждается.

Растение ведёт себя так же (на L4: совместно 0,93 при радиусе 1,53 м против 2,11 м у раздельной; только метки — 0,86; только поза — 0,86), но со значимой долей отказов (около 0,6): в нескольких сценах детектор пропускает растение целиком или подменяет его классом `wall_cabinet`, `box`,

desk_organizer.

Тумба под ТВ — отрицательный результат, который важнее положительных. В двух сценах из 21 детектор уверенно принимает тумбу целиком за другой класс (bench в v3_sc0_staging_12, rug в v3_sc2_staging_13; промах 5,6 и 6,5 м). При $\alpha = 0,1$ и 13 калибровочных сценах квантиль равен максимуму, и любая такая сцена в калибровке приводит к отказу: доля отказов 0,71–0,95. Это корректное поведение: с данным детектором гарантировать тумбу на уровне 90 % нельзя, и калибровка это сообщает, а не прячет.

Деление по Бонферрони ($\alpha/2 + \alpha/2$) при 13 калибровочных сценах невозможно (нужно не меньше 19), поэтому на практике отдельная калибровка доступна только в наивной форме без гарантии композиции — и в наших данных она переплачивает радиусом, а не недопокрывает. Эффект композиции проявился как консервативность, а не как недопокрытие: синтетический дрейф не зависит от ошибок детектора, и сумма двух квантилей оказывается с запасом (ср. [6], где недопокрытие возникает при положительной корреляции ошибок).

5.2. Миссии: безопасность и цена гарантии

Основная конфигурация миссий — два класса, для которых сертификат в принципе возможен (растение, велосипед); тумба под ТВ остаётся обычным препятствием. Этот выбор сделан после анализа покрытия и поэтому приводится вместе с системной конфигурацией (все три класса). Задачи — «проезд мимо»: старт и цель не ближе 1,5 м к запретным объектам, а кратчайший путь по одной лишь геометрии проходит ближе 0,5 м к растению или велосипеду. Так безопасный объезд существует, а планировщик, недооценивающий след объекта, «срезает угол». В 15 сценах из 21 нашлось 233 таких задачи; на каждый уровень дрейфа — 5 реализаций.

Таблица 3: Миссии (растение и велосипед): доля задач с найденным путём, доля нарушений среди найденных путей, доля успешных миссий (путь найден, без нарушений и столкновений, цель достигнута)

Ветка	L0			L2			L4		
	путь	наруш.	успех	путь	наруш.	успех	путь	наруш.	успех
без калибровки	0,99	0,27	0,73	0,97	0,32	0,65	0,26	0,34	0,17
покадровая CP меток	0,27	0,00	0,27	0,28	0,00	0,28	0,04	0,23	0,03
только метки	0,32	0,00	0,32	0,31	0,00	0,31	0,10	0,00	0,10
только поза	0,99	0,27	0,73	0,96	0,20	0,77	0,09	0,00	0,09
раздельно (сумма)	0,32	0,00	0,32	0,31	0,00	0,31	0,00	0,00	0,00
совместно	0,32	0,00	0,32	0,31	0,00	0,31	0,03	0,00	0,03
оракул	1,00	0,00	1,00	0,98	0,00	0,98	0,98	0,00	0,98




Рис. 2: Миссии по уровням дрейфа: нарушения среди найденных путей, успех миссии, доля найденных путей




Рис. 3: Пример задачи «проезд мимо» при дрейфе L2 (сцена v3_sc0_staging_20): красное — истинные следы растения и велосипеда, серое — препятствия, линия — граница запретной зоны ветки в системе координат планировщика. Без калибровки зона не покрывает часть растения, и кратчайший путь проходит ближе 0,5 м (чёрные точки); совместная калибровка покрывает объект, путь объезжает его

- Планировщик *без калибровки* находит путь почти всегда, но 27–37 % его путей проходят ближе безопасного расстояния к истинному запретному объекту (L0–L3). Калибровка только по позе без дрейфа совпадает с ним (радиус 0) и при дрейфе снижает нарушения лишь частично (20 % на L2).
- Все ветки с откалиброванным радиусом по меткам (только метки, отдельно, совместно) дают *ноль нарушений* на всех уровнях. Цена — запретная зона около 1,3 м (0,5 м безопасности плюс $\approx 0,8$ м запаса), из-за которой путь находится лишь в 27–32 % задач, тогда как оракул (истинная карта) решает 98–100 %. Эта разница целиком — плата за недопокрытие объектов детектором, выраженная в метрах. Это доля на специально трудных задачах; на случайных задачах совместная ветка находит безопасный путь в 78 % случаев без дрейфа (разд. 5.3).
- Различие совместной и раздельной ветки в миссиях скромное и проявляется с ростом дрейфа: на L3 путь находится в 30 против 27 % задач, первый путь короче (1,05 против 1,08 от оракула), на L4 — 3 против 0 %. Калибровка только по меткам на L4 находит больше путей (10 %), но её покрытие на этом уровне уже ниже номинала (0,76–0,86, табл. 2).
- В системной конфигурации (все три класса) отказ сертификата тумбы переводит планировщик на запасной вариант «держаться от всех препятствий»: откалиброванные ветки находят путь лишь в 23 % задач без дрейфа и в 5–8 % на L2–L3. Один класс, который нельзя гарантировать, почти обездвиживает робота.

5.3. Сравнение с ближайшей работой в её условиях

Доля задач с найденным путём (≈ 30 %) получена на специально трудных задачах «проезд мимо». С опубликованным успехом миссий Sundarsingh и др. [4] (98,36 %) она несравнима: у них другая среда (открытая площадка 70×25 м с машинами, людьми и деревьями), известная поза, закрытый словарь из пяти классов, случайные старт и цель и режим исследования, когда пути нет. Их данных у нас нет. Поэтому сравниваются *методы* на наших сценах в *их* условиях:

- поза известна;
- закрытый словарь из пяти классов (растение, велосипед, тумба, диван, стол): из 98 текстовых эмбеддингов детектора оставлены пять строк, что совпадает с перенастройкой словаря;
- $1 - \alpha = 0,95$;
- случайные задачи: те же правила для старта и цели, но без отбора по близости к объекту, по 20 задач на сцену.

Их калибровка воспроизведена как ветка «покадровая СР меток»: порог по худшей клетке следа, планирование по самой осторожной метке клетки. Режим исследования не воспроизводился. Затем к тем же условиям добавлен дрейф позы (табл. 4, рис. 4).

Таблица 4: Случайные задачи: покрытие (минимум по растению и велосипеду), доля успешных миссий (безопасный путь до цели) и доля опасных миссий (путь ближе 0,5 м к запретному объекту)

Условия	Дрейф	покадровая СР меток			совместно			без калибровки		оракул
		покр.	успех	опасно	покр.	успех	опасно	успех	опасно	
их: 5 классов, 95 %	известна	1,00	0,43	0,000	0,94	0,42	0,000	0,96	0,040	1,00
	L2	0,42	0,40	0,000	0,94	0,61	0,000	0,92	0,042	0,97
	L3	0,10	0,32	0,002	0,94	0,50	0,000	0,82	0,049	0,97
наши: 98 подсказок, 90 %	известна	1,00	0,43	0,000	0,93	0,78	0,000	0,95	0,043	1,00
	L2	0,41	0,40	0,000	0,93	0,74	0,000	0,91	0,050	0,97
	L3	0,10	0,32	0,002	0,94	0,68	0,000	0,82	0,056	0,97
	L4	0,03	0,09	0,000	0,93	0,17	0,000	0,29	0,021	0,98

- В их условиях при известной позе методы равны: успех 0,43 и 0,42, опасных миссий нет ни у того, ни у другого. Наш метод здесь не лучше.
- При дрейфе их гарантия перестаёт выполняться. Покрытие падает до 0,42 при 2 см и до 0,10 при 7 см дрейфа. Совместная калибровка держит 0,94 и при этом даёт больше успешных миссий: 0,61 и 0,50 против 0,40 и 0,32.
- С открытым словарём наш метод даёт в 1,8 раза больше успешных миссий уже при известной позе: 0,78 против 0,43, при дрейфе — 0,74 и 0,68 против 0,40 и 0,32. Опасных миссий нет у обоих.
- Без калибровки успешны 95 % миссий, но 4–6 % из них опасны. Их метод и наш убирают опасные миссии полностью, но наш отказывается от меньшей доли задач.




Рис. 4: Покадровая калибровка меток в духе [4] против совместной калибровки расстояния промаха на случайных задачах: сверху — их условия (закрытый словарь, 95 %), снизу — наши (открытый словарь, 90 %)

Почему их калибровка у нас вырождается: в обоих словарях порог получается $\lambda^* = 0$, т. е. запретной считается любая занятая клетка. Сначала проверено предположение, что дело в мелкой сетке (у них 1 м). Обе калибровки повторены при известной позе на сетках 5, 25, 50 и 100 см (scripts/grid_resolution.py). Порог равен нулю на *всех* сетках, а доля свободного пространства, которое отнимает их запретная зона, растёт с 64 % при 5 см до 100 % при 1 м. Причина — полные про-

махи детектора: в части сцен до некоторых клеток объекта не доходит ни одного наблюдения его класса. При худшей клетке как счёте одна такая сцена делает порог нулевым. Калибровка в пространстве меток может сказать лишь «эта клетка может быть растением», но не «растение где-то рядом». Расстояние промаха выражает именно это и поэтому остаётся информативным при пропусках.

Доля задач с найденным путём у совместной ветки на случайных задачах — 78 % при известной позе и 72 % при дрейфе 7 см против 30 % на задачах «проезд мимо». Остальное до 98–100 % оракула — цена ошибок детектора.

5.4. Уровень риска: сколько стоит гарантия

Миссии и покрытие пересчитаны при $\alpha \in \{0,05; 0,1; 0,2; 0,3\}$ (рис. 5, табл. 5; дрейф L3). При $\alpha = 0,05$ нужно не меньше 19 калибровочных сцен, поэтому разбиение 19/2, при остальных — 13/8.




Рис. 5: Уровень риска α против покрытия (слева, тонкая линия — номинал $1 - \alpha$), радиуса запаса (в центре) и исхода миссий (справа); дрейф L3, растение (сплошная) и велосипед (пунктир)

Таблица 5: Цена гарантии при разных α (L3): покрытие и радиус совместной ветки, доля отказов по растению, доля задач с найденным путём и доля нарушений

α	покрытие		$\hat{q}$, м		отк.	путь найден			наруш.
	раст.	велос.	раст.	велос.	раст.	совм.	разд.	оракул	совм.
0,05	0,95	0,95	0,85	0,76	0,73	0,10	0,02	0,99	0,000
0,10	0,94	0,94	0,81	0,75	0,55	0,30	0,27	0,99	0,000
0,20	0,87	0,86	0,75	0,70	0,00	0,31	0,29	0,99	0,002
0,30	0,72	0,72	0,60	0,50	0,00	0,31	0,30	0,99	0,002

- Совместная ветка держит номинал при каждом α (0,95; 0,94; 0,86–0,87; 0,72), раздельная остаётся консервативной и при $\alpha = 0,3$ (0,82–0,91).
- Отказы по растению исчезают при $\alpha \geq 0,2$: сцена, где детектор пропускает растение целиком, перестаёт определять квантиль.
- Радиус убывает медленно: от 0,81 до 0,60 м для растения и от 0,75 до 0,50 м для велосипеда при росте α с 0,1 до 0,3. Решаемость миссий почти не растёт: 30 → 31 % задач. Ниже $\alpha = 0,1$ она резко падает: 10 % при $\alpha = 0,05$.
- Нарушения у совместной ветки остаются на уровне 0,2 % задач даже при $\alpha = 0,3$, потому что гарантия по классу и сцене консервативна по отношению к отдельной задаче.

Вывод: торговаться уровнем риска почти бесполезно. Решаемость упирается в «пол» ошибки восприятия: даже при $\alpha = 0,3$ истинный след выходит за область класса на 0,5–0,6 м. Сократить запас может только лучшее восприятие, а не более смелая калибровка.

5.5. Стресс-тест композиции

На синтетическом дрейфе раздельная калибровка переплачивает радиусом, но не недопокрывает (разд. 5.1). Причина в том, что дрейф независим от ошибок детектора. Чтобы проверить, когда сумма квантилей перестаёт быть валидной, ошибки меток оставлены реальными, а позе задана сценная смесь.

В k сценах из 21 происходит «отказ локализации»: реализации берутся с уровня L5. В остальных сценах — с уровня L1. Зависимость задаётся выбором этих сцен:

- *согласованно*: там, где метки хуже всего;
- *разнесённо*: там, где метки лучше всего;
- *случайно*: случайное подмножество.

Уровень риска $\alpha = 0,3$ взят потому, что при $\alpha = 0,1$ и 13 сценах квантиль равен максимуму и редкие отказы всегда попадают в радиус.




Рис. 6: Покрытие раздельной (розовая) и совместной (синяя) калибровки в зависимости от доли сцен с отказом локализации и от того, в каких сценах происходят отказы; $\alpha = 0,3$, нижняя пунктирная линия — граница $1 - 2\alpha$, которую гарантирует сумма квантилей

Покрытие раздельной схемы зависит от того, как распределены отказы (рис. 6):

- при согласованных отказах оно 0,76–0,84;
- при разнесённых падает до 0,66 для растения (номинал 0,70) при 19–24 % сцен с отказом.

Совместная ветка держит 0,71–0,78 во всех конфигурациях. Теоретически сумма двух квантилей гарантирует только $1 - 2\alpha$: если промах совместной карты не больше суммы промахов меток и позы, то по неравенству Буля $P(\text{оба не превышены}) \geq 1 - 2\alpha$. Достигается ли эта граница, решает зависимость ошибок, которую на практике заранее не знают. Совместная калибровка от неё не зависит. Это согласуется с выводом [6] о том, что маргинальная калибровка модулей не переносится на систему. Наш случай — недопокрытие при *разнесённых* редких отказах.

5.6. Проверка упрощений: маски, реальная одометрия, другие сцены

Основной эксперимент опирается на три упрощения: маски из рамок, синтетический дрейф и одно семейство сцен. Каждое из них проверено отдельно (табл. 6).

Таблица 6: Проверка упрощений: покрытие и медианный радиус (м) для велосипеда и растения, $\alpha = 0,1$; $\dagger$ — ветка отказывается в половине разбиений или чаще, приведён радиус в остальных

Вариант	велосипед						растение					
	метки покр.	$\hat{q}$	метки покр.	$\hat{q}$	совместно покр.	$\hat{q}$	метки покр.	$\hat{q}$	метки покр.	$\hat{q}$	совместно покр.	$\hat{q}$
рамка + глубина, L0	0,93	0,75	0,93	0,75	0,93	0,75	0,93	0,85 $\dagger$	0,93	0,85 $\dagger$	0,93	0,85 $\dagger$
рамка + глубина, L3	0,93	0,75	0,99	0,90	0,94	0,75	0,94	0,85 $\dagger$	0,96	1,09 $\dagger$	0,94	0,81 $\dagger$
рамка + глубина, L4	0,76	0,75	0,97	1,61	0,93	1,18	0,86	0,85 $\dagger$	0,95	2,11 $\dagger$	0,93	1,53 $\dagger$
MobileSAM, L0	0,93	0,75	0,93	0,75	0,93	0,75	0,93	0,61 $\dagger$	0,93	0,61 $\dagger$	0,93	0,61 $\dagger$
MobileSAM, L3	0,93	0,75	0,97	0,90	0,93	0,75	0,94	0,61 $\dagger$	0,95	0,86 $\dagger$	0,95	0,61 $\dagger$
MobileSAM, L4	0,78	0,75	0,98	1,61	0,93	1,03	0,82	0,61 $\dagger$	0,94	1,92 $\dagger$	0,95	1,63 $\dagger$
BO, каждый 2-й кадр	0,67	0,75	0,92	2,46 $\dagger$	0,93	1,95 $\dagger$	0,74	0,85 $\dagger$	0,97	2,98 $\dagger$	0,96	2,31 $\dagger$
BO, каждый 4-й кадр	0,51	0,75	0,97	3,15 $\dagger$	0,96	2,41 $\dagger$	0,75	0,85 $\dagger$	0,99	3,46 $\dagger$	0,97	2,42 $\dagger$
HM3D (OOD), L0	—	—	—	—	—	—	0,50	0,85	0,50	0,85	0,50	0,85
HM3D (OOD), L3	—	—	—	—	—	—	0,50	0,85	0,50	1,07	0,50	0,82

Маски MobileSAM. Рамки детектора переведены в маски MobileSAM [16] — облегчённым SAM, как в ConceptGraphs.

- Типичный промах велосипеда без дрейфа уменьшился почти в 9 раз: медиана 0,43 → 0,05 м. Наихудший не изменился (0,75 м). Для растения медиана 0,49 → 0,32 м.
- При 13 калибровочных сценах и $\alpha = 0,1$ квантиль равен максимуму. Поэтому радиус велосипеда не изменился (0,75 м), а у растения уменьшился с 0,85 до 0,61 м.
- Покрытие совместной ветки сохранилось (0,93–0,95).

Значит, при малом числе калибровочных сцен запас определяет наихудшая сцена: улучшать нужно хвост ошибок восприятия, а не среднее.

Миссии с масками SAM (те же 233 задачи) показывают обе стороны.

- Без дрейфа карта без калибровки стала безопасной: 0 нарушений против 27 % с масками из рамок.
- При дрейфе нарушения возвращаются: 9,5 % найденных путей на L3 и 19,5 % на L4.
- Откалиброванные ветки по-прежнему находят путь лишь в 21–38 % задач, потому что радиус задаёт худшая сцена. Нарушения у них — 1–2 % путей на L1–L3, в пределах гарантии по классу и сцене.

Хорошая сегментация снимает ошибку меток в типичной сцене, но не ошибку позы. Поэтому при дрейфе гарантия нужна и с хорошим сегментатором, а её консервативность при 13 сценах — плата за малую калибровочную выборку.

Реальная визуальная одометрия. Синтетический дрейф заменён на RGB-D одометрию Open3D [17]: плотная фотометрическая и геометрическая невязка [18], параметры по умолчанию. Одометрия работает кадр к кадру, без замыканий циклов, и применяется к тем же сценам.

- Каждый 8-й кадр не годится: повороты на месте по 16° за шаг срывают сопоставление, и АТЕ на dev-сцене доходит до 12 м. Поэтому скачан каждый 2-й кадр (RGB и глубина).
- Добавлено плоское ограничение наземного робота: каждое относительное движение проецируется на рысканье и сдвиг по полу. Без него одна неудачная пара кадров у стены опрокидывала траекторию на 89°.
- Параметры по истине *не* подбирались: перебор на трудных участках не дал настройки, лучшей везде, а выбор по эталонным позам был бы подгонкой под тест.

Ошибка такой одометрии — тяжёлый хвост по сценам: АТЕ от 3,5 см до 3,9 м, медиана 78 см, дрейф в конце 1–27 % пути. Ошибка случается в основном на отдельных шагах — поворотах на месте вблизи стен. Вариант с каждым 4-м кадром даёт медиану 2,6 м и служит режимом «потерянной локализации». Результаты калибровки (табл. 6, рис. 7):

- ветка «только метки» *молча* теряет покрытие: 0,67 для велосипеда и 0,74 для растения (ВО, каждый 2-й кадр), 0,51 для велосипеда (каждый 4-й). Это гипотеза H1 уже на реальной ошибке позы;
- совместная ветка держит покрытие (0,93–0,97), но отказывается в 60 % разбиений для велосипеда и в 86 % для растения. В остальных её радиус около 2 м;
- в миссиях (216 задач, у которых старт и цель остаются в пределах карты):
 - карта без калибровки находит путь лишь в 23 % задач, и 44 % этих путей нарушают безопасное расстояние, а 38 % проходят через истинные препятствия;
 - ветка «только метки» находит путь в 8 задачах, 6 из них небезопасны;
 - совместная ветка отказывается от миссии в 89 % задач.

Иначе говоря, при одометрии без замыканий циклов полезного сертификата нет, и совместная калибровка честно об этом сообщает. Калибровка только по меткам выдаёт ложный сертификат. Чтобы гарантия стала полезной, нужна оценка позы с ограниченной ошибкой (SLAM с замыканиями, релокализация), а не другая калибровка.




Рис. 7: Проверка упрощений: покрытие (сверху; линия — номинал 0,9) и медианный радиус (снизу; штриховка — ветка отказывается в половине разбиений или чаще) для масок MobileSAM, реальной визуальной одометрии и сцен HM3D

Другие сцены (вне распределения). Гарантия выведена для обмениваемых сцен. Чтобы увидеть, что происходит без обмениваемости, радиусы, откалиброванные на всех 21 сцене ReplicaCAD, проверены на сценах HM3D [19] из OSMa-Bench. Это реальные сканы домов, опубликованные только в условии `no_lights`.

- Категории HM3D сведены к классам ReplicaCAD (`plant`, `decorative plant` → растение, `bicycle` → велосипед), высота пола оценена по эталонным точкам пола.
- Из 8 сцен две многоэтажные исключены. Растение видно с траектории лишь в двух сценах из шести, велосипед и тумба — ни в одной.
- В сцене 00813 растение найдено хорошо: промах 0,18 м, лучше медианы ReplicaCAD.
- В сцене 00815 декоративное растение детектор делит между `plant_stand`, `sculpture` и `pot`, и промах 2,9 м.

Покрытие на двух сценах — 0,5 при номинале 0,9 и у совместной, и у остальных веток. Две сцены — это иллюстрация, а не оценка. Вывод совпадает с наблюдением [4] о падении покрытия при сдвиге условий: гарантия не переносится между семействами сцен, калибровку нужно повторять в целевой среде.

5.7. Предсказывает ли качество карты безопасность (H4)

Для каждой сцены сопоставлены mIoU карты при истинных позах и доля нарушений планировщика без калибровки (рис. 8). Ранговая корреляция близка к нулю: $\rho = -0,16$ ($p = 0,57$, 15 сцен); для IoU только запретных классов знак даже обратный ожидаемому ($\rho = +0,51$, $p = 0,05$). При разбросе mIoU сцен от 0,17 до 0,34 метрика карты не говорит, насколько опасно по ней ехать: безопасность определяется наихудшим недопокрытием объекта, а mIoU усредняет по клеткам. Гипотеза H4 подтверждается (с оговоркой о малом числе сцен).




Рис. 8: Качество карты против доли нарушений планировщика без калибровки (одна точка — сцена, L0)

5.8. Планировщик на ужесточённой карте (H5)

На уровне L2 запретные зоны совместной ветки — те же, что в миссиях, — масштабированы коэффициентом m (угловая зона [20]); на задачах, решаемых точным поиском, сравниваются три выборочных планировщика с бюджетом 1500 расширений (табл. 7, рис. 9): P — RRT-Connect с равномерной выборкой, Y — угловая динамическая зона по опубликованному правилу (расширение конуса, пока образцы попадают в препятствие), A — предложенная модификация: конус расширяется после каждого заблокированного расширения дерева и сужается после успешного.

Таблица 7: Выборочные планировщики на ужесточённых картах (растение и велосипед, L2, 233 задачи, 2 запуска на задачу)

m	своб.	решаемо	решено за бюджет			итераций (медиана)			длина / кратчайший		
			P	Y	A	P	Y	A	P	Y	A
0,0	0,96	0,97	0,93	0,91	0,93	66	192	94	1,15	1,14	1,11
0,5	0,89	0,67	0,75	0,71	0,73	88	236	113	1,18	1,16	1,13
1,0	0,79	0,30	0,89	0,89	0,86	92	213	111	1,19	1,17	1,17
1,5	0,70	0,16	0,85	0,80	0,81	84	256	99	1,21	1,18	1,14




Рис. 9: Слева: доля свободного пространства и решаемых задач; в центре: доля решённых за бюджет B при откалиброванном запасе; справа: длина первого найденного пути относительно кратчайшего

- Ограничивает свободное пространство, а не поиск: при откалиброванном запасе решаемы лишь 30 % задач (при $m = 0$ — 97%), а решаемые задачи все три планировщика решают за бюджет примерно одинаково часто (0,86–0,89).
- Опубликованное правило угловой зоны требует в 2,3–3,0 раза больше расширений, чем равномерная выборка: на ужесточённых картах проходы часто смещены от прямой между деревьями, а конус расширяется только при образцах в препятствии, которых в почти свободном пространстве мало.
- Модификация с расширением конуса по заблокированным расширениям сокращает это до 1,2–1,4 раза. Её первые пути не длиннее, чем у других: 1,11–1,17 от кратчайшего против 1,15–1,21

у равномерной выборки; при откалиброванном запасе она наравне с опубликованным правилом (1,17). Т. е. свойство квазиоптимальности исходного метода сохраняется.

Это первый, предварительный результат для ВКР: вклад планировщика на картах с калиброванным запасом — качество и стоимость пути в суженном пространстве; адаптация угловой зоны к смещённым проходам — конкретная исследовательская задача.

6. Обсуждение

Что подтвердилось. Открытословарная карта почти никогда не покрывает истинный след объекта целиком, поэтому без калиброванного запаса планировщик систематически «срезает углы» возле запретных объектов. Калибровка только в пространстве меток (покадровая СР) у открытого словаря вырождается в «запретно всё занятое» и при этом ломается от сантиметров дрейфа: она требует, чтобы каждая клетка объекта попала в множество, а дрейф сдвигает клетки. Радиус, откалиброванный только по меткам, держится, пока дрейф мал по сравнению с ошибкой меток (до ~ 7 см АТЕ в наших данных), и проваливается при одометрическом дрейфе. Радиус только по позе недопокрывает при любом реалистичном дрейфе, потому что не видит ошибок детектора. Совместная калибровка расстояния промаха держит номинальное покрытие на всех уровнях и даёт наименьший из валидных запасов. В условиях ближайшей работы [4] (известная поза, закрытый словарь) она не лучше её калибровки меток, но и не хуже. Преимущество появляется ровно там, где нарушено допущение об известной позе, и при открытом словаре. Там калибровка меток вырождается при любом шаге сетки, потому что не может выразить «объект где-то рядом».

Что оказалось не так, как ожидалось. На синтетическом дрейфе эффект композиции проявился не как недопокрытие раздельной схемы (ср. [6]), а как переплата радиусом на 36–38 % (на L4). Синтетический дрейф независим от ошибок детектора, и сумма двух квантилей получается с запасом. Ожидание, что недопокрытие даст положительная корреляция ошибок, не подтвердилось. В стресс-тесте (разд. 5.5) согласованные отказы делают раздельную схему ещё консервативнее. Недопокрывает она, наоборот, при *разнесённых* редких отказах — когда локализация отказывает в сценах, где с метками всё хорошо, — до 0,66 при номинале 0,70. Это согласуется с теорией: сумма квантилей гарантирует лишь $1 - 2\alpha$, и где в этом диапазоне окажется покрытие, решает неизвестная заранее зависимость ошибок.

Второе неожиданное наблюдение: при 13 калибровочных сценах запас определяется наихудшей сценой. Маски SAM почти в 9 раз уменьшили типичный промах велосипеда, но не радиус. Повышение α до 0,3 уменьшило радиус лишь на 0,2 м и почти не добавило решаемости. Сократить запас можно только улучшением хвоста ошибок восприятия или большей калибровочной выборкой.

Третье: реальная одометрия без замыканий циклов ошибается не «плавно», как модель дрейфа, а скачками на отдельных шагах (повороты на месте у стен). Это даёт тяжёлый хвост ошибки по сценам. Совместная калибровка в этом режиме честно отказывается, а калибровка только по меткам выдаёт ложный сертификат (покрытие 0,67 при номинале 0,9).

Главная находка для лаборатории. Узкое место — не дрейф и не пограничные ошибки сегментации, а уверенная подмена класса целого объекта. Для тумбы под ТВ это происходит в 2 сценах из 21, т. е. чаще, чем допускает $\alpha = 0,1$, и честная калибровка отказывается давать гарантию. Метрики качества карты (mIoU, f-mIoU) этого не отражают: они усредняют по клеткам и классам, а безопасность определяется наихудшим объектом в сцене.

Ограничения и угрозы валидности.

- Основной дрейф синтетический. Реальная одометрия проверена только в варианте кадр к кадру без замыканий циклов: её ошибка слишком велика для полезного сертификата, а промежуточный режим реального SLAM с замыканиями не проверен.
- Одно условие освещения: остальные условия OSMA-Bench не опубликованы. Ось освещения — в дальнейших шагах.
- Сцены ReplicaCAD — перестановки мебели одной квартиры; обменность сцен выполняется, но разнообразие ограничено. Классы и порог λ_0 выбраны по dev-сцене, но набор запретных классов для миссий (без тумбы) уточнён после анализа покрытия — это явно оговорено.
- Гарантия маргинальна по сценам; при 13 калибровочных сценах распределение покрытия по разбиениям широкое (10-й перцентиль 0,75–0,83 у совместной ветки при среднем 0,93), что согласуется с бета-распределением покрытия split-CP при малом n .

- Восприятие — детектор рамок с масками по глубине или MobileSAM, а не полный картограф (ConceptGraphs, BBQ); вывод о подмене классов нужно перепроверить на них.
- Проверка вне распределения (HM3D) — две сцены с одним классом: это иллюстрация, а не оценка.
- 2D-карта и плоское движение; ошибка локализации во время исполнения плана не моделируется.

7. Связь с ВКР и дальнейшие шаги

Где здесь **планирование**. Калибровка даёт гарантию, не зависящую от планировщика: любой путь, соблюдающий раздутые запретные зоны, безопасен с вероятностью не ниже $1 - \alpha$. Но раздувание сужает свободное пространство и создаёт узкие проходы. Поэтому вклад планировщика измеряется не гарантией, а тем, как часто и как быстро он решает *ужесточённую* задачу. Это постановка для ВКР по планированию движения в условиях неопределённости (научный руководитель И. С. Довгополик): двунаправленный RRT* с угловой динамической зоной выборки, стоимостью ненадёжности карты и откалиброванным запасом, который поставляет модуль из этой работы. Предварительный эксперимент раздела 5.8 показывает, как решаемость за фиксированный бюджет зависит от масштаба запаса.

Мост к SLAM (второй год). Постановка (3.2)–(3.3) не меняется при замене синтетического дрейфа реальной ошибкой оценщика позы; это уже проверено на визуальной одометрии. Следующие шаги:

1. Заменить одометрию кадр к кадру (разд. 5.6) на SLAM с замыканиями циклов — ORB-SLAM3, RTAB-Map или SLAM лаборатории. Это промежуточный режим ошибки позы, в котором гарантия может стать полезной: ошибка ограничена, но не нулевая.
2. Увеличить число калибровочных сцен. Сейчас при 13 сценах запас определяет худшая сцена (разд. 5.4, 5.6). Данные OSMa-Bench++ (40 сцен, 4 условия освещения) позволяют и работать при $\alpha = 0,05$, и проверить ось освещения.
3. Сделать запас зависящим от объекта, а не одним на класс: нормированный счёт, у которого радиус растёт с неуверенностью найденного пятна. Диагностика показывает связь промаха велосипеда с уверенностью карты ($\rho \approx -0,5$).
4. Заменить детектор рамок полным картографом (ConceptGraphs, BBQ) и проверить, сохраняются ли полные промахи и подмены класса целого объекта.
5. Учесть ошибку локализации во время исполнения плана: сейчас гарантия относится к системе координат планировщика в момент запроса.

Открытый вопрос для лаборатории. Если подмена класса целого объекта (тумба под ТВ → скамейка, ковёр) встречается чаще, чем в α доле сцен, никакая калибровка класс-специфичной области не даст полезной гарантии для этого класса: честный ответ — отказ. Это перекладывает вопрос с планировщика на картограф: нужна не только высокая mIoU, но и редкость уверенных подмен для классов, важных для безопасности. Такую метрику (доля сцен с полной подменой класса) естественно добавить в протокол OSMa-Bench.

Список литературы

- [1] ConceptGraphs: Open-Vocabulary 3D Scene Graphs for Perception and Planning / Q. Gu [и др.] // 2024 IEEE International Conference on Robotics and Automation (ICRA). — 2024. — P. 5021–5028. — DOI 10.1109/ICRA57147.2024.10610243.
- [2] OSMa-Bench: Evaluating Open Semantic Mapping Under Varying Lighting Conditions / M. Popov [и др.] // 2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). — 2025. — P. 10786–10791. — DOI 10.1109/IROS60139.2025.11247603.
- [3] 3D Scene Graphs: Open Challenges and Future Directions / D. Rotondi [и др.] // arXiv preprint. — 2026. — arXiv:2606.19383. — (Приглашённая статья для Annual Review of Control, Robotics, and Autonomous Systems, т. 10, по комментарию arXiv.)
- [4] Safe Planning in Unknown Environments Using Conformalized Semantic Maps / D. S. Sundarsingh [и др.] // IEEE Robotics and Automation Letters. — 2026. — Vol. 11, no. 4. — P. 4921–4928. — DOI 10.1109/LRA.2026.3668466.
- [5] Perceive With Confidence: Statistical Safety Assurances for Navigation with Learning-Based Perception / Z. Mei [и др.] // The International Journal of Robotics Research. — 2025. — Vol. 45, no. 6. — P. 938–967. — DOI 10.1177/02783649251378151.

- [6] Baral R. Marginal Calibration Does Not Compose: Hidden Dependence in Modular Robot Navigation / R. Baral // arXiv preprint. — 2026. — arXiv:2609.23731. — (Воркшоп «Rethinking Uncertainty for Modern Robotics Paradigms», IROS 2026.)
- [7] Kurkova R. OSMa-Bench++: Toward Open-Ended Benchmarking of Semantic Mapping for Manipulation with Prompt-Generated Synthetic Scenes / R. Kurkova, M. Popov, S. Kolyubin // arXiv preprint. — 2026. — arXiv:2605.26831. — (Воркшоп ICRA 2026 «Open Challenges for Rigorous Robot Perception».)
- [8] Correia Marques J. M. On the Overconfidence Problem in Semantic 3D Mapping / J. M. Correia Marques, A. Zhai, S. Wang, K. Hauser // 2024 IEEE International Conference on Robotics and Automation (ICRA). — 2024. — P. 11095–11102. — DOI 10.1109/ICRA57147.2024.10611306.
- [9] Learnable Conformal Prediction with Context-Aware Nonconformity Functions for Robotic Planning and Perception / D. Kumar [и др.] // 2026 IEEE International Conference on Robotics and Automation (ICRA). — 2026. — arXiv:2509.21955. — (Сверка версии в трудах ICRA с arXiv не проводилась.)
- [10] Natraj S. Conformal Constraint Tightening for Chance-Constrained Motion Planning with Unknown Dynamics / S. Natraj, B. Sinopoli, Y. Kantaros // arXiv preprint. — 2026. — arXiv:2607.22409.
- [11] P-POSEMEM: Projective Semantic Memory for Consistent Language Grounding under Pose-Graph Rewrites / H. Sier [и др.] // arXiv preprint. — 2026. — arXiv:2609.15475.
- [12] YOLO-World: Real-Time Open-Vocabulary Object Detection / T. Cheng [и др.] // 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2024. — P. 16901–16911. — DOI 10.1109/CVPR52733.2024.01599.
- [13] Habitat 2.0: Training Home Assistants to Rearrange their Habitat / A. Szot [и др.] // Advances in Neural Information Processing Systems (NeurIPS). — 2021. — arXiv:2106.14405.
- [14] Angelopoulos A. N. A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification / A. N. Angelopoulos, S. Bates // arXiv preprint. — 2021. — arXiv:2107.07511.
- [15] Safe Planning in Dynamic Environments using Conformal Prediction / L. Lindemann [и др.] // IEEE Robotics and Automation Letters. — 2023. — Vol. 8, no. 8. — P. 5116–5123. — DOI 10.1109/LRA.2023.3292071.
- [16] Faster Segment Anything: Towards Lightweight SAM for Mobile Applications / C. Zhang, D. Han, Y. Qiao [и др.] // arXiv preprint. — 2023. — arXiv:2306.14289.
- [17] Zhou Q.-Y. Open3D: A Modern Library for 3D Data Processing / Q.-Y. Zhou, J. Park, V. Koltun // arXiv preprint. — 2018. — arXiv:1801.09847.
- [18] Steinbrücker F. Real-time visual odometry from dense RGB-D images / F. Steinbrücker, J. Sturm, D. Cremers // 2011 IEEE International Conference on Computer Vision Workshops (ICCV Workshops). — 2011. — P. 719–722. — DOI 10.1109/ICCVW.2011.6130321.
- [19] Habitat-Matterport 3D Dataset (HM3D): 1000 Large-scale 3D Environments for Embodied AI / S. K. Ramakrishnan, A. Gokaslan, E. Wijmans [и др.] // NeurIPS Datasets and Benchmarks. — 2021. — arXiv:2109.08238.
- [20] Довгополик И. С. Квазиоптимальный алгоритм планирования движения робототехнической системы по кратчайшему пути со случайной выборкой / И. С. Довгополик, О. И. Борисов // Известия вузов. Приборостроение. — 2025. — Т. 68, № 5. — С. 450–455. — DOI 10.17586/0021-3454-2025-68-5-450-455.