

Конформная калибровка открытословарных семантических карт при ошибках метки и позы

Conformal Calibration of Open-Vocabulary Semantic Maps under Label and Pose Uncertainty

Щетинкин Сергей Олегович
Университет ИТМО

октябрь 2026 · код и данные: <https://github.com/byoverr/label-pose-conformal-nav>

Аннотация

Робот, который объезжает объекты по открытословарной семантической карте, получает две ошибки сразу. Детектор недорисовывает объекты или путает класс, а оценка позы дрейфует, и объекты попадают на карту не туда. Статистические гарантии для планирования по картам восприятия обычно калибруют ошибку восприятия при известной позе.

Мы калибруем одну величину — расстояние промаха: насколько истинный объект выходит за свою область на карте, построенной по оценённым позам, в системе координат планировщика. Её конформный квантиль по сценам даёт запас. Любой путь, который держится от области класса на безопасном расстоянии плюс этот запас, безопасен с заданной вероятностью, какой бы планировщик его ни построил; если запас получается бесполезно большим, метод отказывается от гарантии.

На 21 сцене OSMa-Bench запасы, откалиброванные только по меткам или только по позе, теряют покрытие под действием другой ошибки, а сумма двух запасов переплачивает до четверти. Калибровка множеств меток вырождается в запрет всех занятых клеток, потому что детектор обрезает край каждого объекта. Цену гарантии задаёт наихудшая калибровочная сцена: один пропущенный детектором объект заставляет его класс отказываться в 24–63 % разбиений. Более сильные детекторы убирают этот пропуск, но у каждого из трёх проверенных находится свой целиком пропущенный класс, а подмену класса создают конкуренты в открытом словаре. Объединение трёх детекторов по максимуму снимает отказы всех классов, а проверка находок CLIP возвращает их: гарантия платит за наихудший промах, и выигрывает полнота. Если вместо отказа сообщать для пути конформную оценку риска, решаемость та же; если калибровать не карту, а ожидаемую долю опасных миссий, успешных миссий почти столько же, сколько без калибровки, при 0,6 % опасных вместо 7–8 %. Пути, сертифицированные по плану, остаются безопасными при исполнении с дрейфом до 7 см. С реальной одометрией без замыканий циклов полезной гарантии нет; SLAM с замыканиями снижает медианную ошибку позы втрое, но запас задают сцены, где замыканий не нашлось.

1. Введение

Открытословарные семантические карты [1] позволяют давать роботу задания словами: «подъезди к дивану», «не подъезжай к велосипеду». Карта собирается из двух ненадёжных источников. Метки даёт детектор или сегментатор открытого словаря, и он ошибается: пропускает объекты, захватывает их не целиком, путает классы. Положение объектов задаёт оценка позы робота, и она дрейфует. Планировщик обычно принимает карту за истину и держит фиксированный зазор до областей запретных классов.

Насколько это опасно, обычно не измеряют. Бенчмарк OSMa-Bench [2] показывает, что качество открытословарных карт сильно падает при смене освещения (f-mIoU ConceptGraphs с 28,00 до 14,29), но проверяет сегментацию и ответы на вопросы по графу сцены, а не движение робота. Обзор трёхмерных графов сцены [3] называет связь ошибок карты с поведением робота открытой проблемой.

Конформное предсказание [4] даёт планировщику гарантию без предположений о распределении ошибок. Sundarsingh и др. [5] калибруют множества меток клеток семантической карты, Perceive With Confidence [6] — раздувание карты занятости; обе работы считают позу робота известной. Отдельно откалиброванные модули при этом не обязаны давать откалиброванную систему [7].

Мы спрашиваем, какую гарантию получает планировщик, когда ошибка метки и ошибка позы действуют вместе, и как её откалибровать. Вклад работы:

- мера несоответствия *расстояние промаха*: поклассовый вариант меры раздувания [6], измеренный в системе координат планировщика на карте, построенной по оценённым позам. Её конформный квантиль даёт запас, который покрывает обе ошибки для любого планировщика, а при слишком большом запасе честно отказывается от гарантии;

- анализ совместной и раздельной калибровки: сумма двух отдельных запасов гарантирует лишь $1 - 2\alpha$, и то при условии, которое из геометрии не следует; мы строим сценарий, где сумма недопокрывает;
- эксперимент на 21 сцене OSMa-Bench с пятью уровнями синтетического дрейфа, реальной визуальной одометрией и SLAM с замыканиями циклов, масками MobileSAM и переносом на HM3D. Мы сообщаем не только покрытие, но и цену гарантии — размер запаса, долю отказов и долю решённых задач — и сравниваем метод с калибровкой множеств меток и с запасом без семантики;
- проверка того, что снижает цену: три детектора по отдельности и вместе, каскад с проверкой CLIP, гарантия на ожидаемую долю опасных миссий вместо гарантии на карту и проверка гарантии при исполнении пути с продолжающимся дрейфом.

2. Связанные работы

Открытословарные карты. ConceptGraphs [1] объединяет маски сегментатора между кадрами в граф объектов с признаками CLIP; метку объекта даёт сходство признаков с текстовым запросом. OSMa-Bench [2] и OSMa-Bench++ [8] оценивают такие карты по трёхмерной сегментации и вопросам к графу сцены при разном освещении, без задачи движения. Наивное байесовское слияние покадровых вероятностей делает семантическую карту переуверенной: ошибка калибровки вокселей 0,451 против 0,124 у пикселей [9], поэтому мы сливаем наблюдения усреднением. Tchuiev и Indelman [10] ведут совместное байесовское распределение над позами и классами и планируют в пространстве убеждений — модельно, без гарантий, не зависящих от распределения.

Конформные гарантии для планирования. В планирование конформное предсказание пришло через прогноз движения других агентов [11]. Yang и др. [12] калибруют ошибку оценки состояния по восприятию и строят управление с барьерными функциями, устойчивыми к этой ошибке; карты и семантики там нет. Shin и др. [13] калибруют поле расстояний до движущихся препятствий целиком и получают ограничение, безопасное для любой траектории MPC; включение ошибок восприятия и оценки состояния в ту же процедуру они называют направлением будущей работы. SCORE [14] задаёт меру на поле знаковых расстояний и получает невыпуклую запретную зону; Learnable CP [15] учит контекстную меру для зазора планировщика и включает в абляции синтетический шум локализации. Natraj и др. [16] ужесточают ограничения на величину конформной оценки расхождения номинальной и истинной динамики; процедура не зависит от планировщика, а планировщик решает тем меньше задач, чем выше требуемая вероятность.

Ближе всего к нам Sundarsingh и др. [5]. Они калибруют множества меток клеток семантической сетки по одной мере на среду — худшей по клеткам, наблюденным вдоль выборки путей, — и планируют по самой осторожной метке клетки. Поза известна, классов пять (включая «свободно»), среды — открытые площадки 70×25 м. В экспериментах использован вариант с гарантией, условной по калибровочной выборке ($\delta = 0,1, 50$ калибровочных сред); при цели 95 % доля корректных карт 93,36 %, успех миссий 98,36 %. Perceive With Confidence [6] калибрует минимальное раздувание карты занятости, при котором она накрывает все препятствия. Наш промах — покласовый вариант этой меры, измеренный в системе координат планировщика на карте, построенной по оценённым позам.

Композиция гарантий и ошибка позы. В синтетическом гауссовом примере Baral [7] два модуля с покрытием 95 %, объединённые в предположении независимости ошибок, дают от 99,98 % при корреляции $-0,9$ до 86,46 % при $+0,9$, а оценка совместной ковариации по калибровочной выборке возвращает номинал. Calafiore [17] складывает отдельные сертификаты через неравенство Буля с распределением риска между модулями. Mahajan и др. [18] показывают, что локальные конформные гарантии карт занятости ослабевают, потому что корреляция вдоль траектории нарушает обменяемость, и восстанавливают покрытие слиянием карт нескольких роботов. Без обменяемости потерю покрытия можно ограничить, взвешивая калибровочные точки [19]. Ошибка позы в семантической памяти реальна и плохо откалибрована: на реальном роботе номинальный 95 %-эллипсоид положения объекта, полученный из графа поз, накрывает лишь 33 % повторных обнаружений [20].

По цитированиям ближайших работ и поиску в arXiv и OpenAlex (октябрь 2026 г.) мы не нашли работы, которая совместно калибрует ошибку метки открытого словаря и ошибку позы робота с планировщиком в контуре. Поиск не исчерпывающий, поэтому вывод о новизне предварительный.

3. Постановка задачи

Сцена и объекты. Сцена Ω — случайный элемент неизвестного распределения $\mathcal{D}$. В сцене есть объекты запретных классов $\mathcal{K}$: объект e имеет класс $k_e \in \mathcal{K}$ и след на полу $F_e \subset \mathbb{R}^2$. Объединение следов класса k обозначим $F_k = \bigcup_{e: k_e=k} F_e$.

Позы. Робот проходит траекторию с истинными позами $T_1, \dots, T_Q \in SE(2)$ и в момент Q получает задание. Оценщик позы выдаёт $\hat{T}_t = E_t T_t$, где $E_t \in SE(2)$ — накопленная к моменту t ошибка. Робот наземный, поэтому ошибка плоская: сдвиг по полу и поворот вокруг вертикали.

Карта. По наблюдениям и оценённым позам строится сетка с шагом Δ . Для клетки j и класса k она хранит долю $p_j(k) \in [0, 1]$ наблюдений клетки, поддерживающих k . Область класса при пороге λ — множество центров клеток

$$A_\lambda(k) = \{c_j : \text{клетка } j \text{ занята, } p_j(k) \geq \lambda\}. \quad (3.1)$$

Система координат планировщика. Путь строится в момент Q в мире, каким его видит робот: свою позу он считает равной $\hat{T}_Q$, поэтому истинный след в его системе координат равен $\hat{F}_k = E_Q F_k$. Точка, наблюденная в момент t , стоит на карте в $E_t x = (E_t E_Q^{-1}) E_Q x$, то есть сдвинута относительно этой истины на относительную ошибку $E_t E_Q^{-1}$. Общее для всей траектории движение G (оценки $G E_t T_t$) сдвигает и карту, и робота одинаково и ничего не меняет; вредны только относительные ошибки.

Безопасность. Путь γ — последовательность положений центра робота. Он безопасен по классу k , если $\text{dist}(x, \hat{F}_k) \geq d$ для всех точек x пути; $d = 0,5$ м — безопасное расстояние от центра робота.

Допущение 1 (исполнение). Робот проходит путь в системе координат планировщика, и ошибка позы за время исполнения не меняется.

Допущение 1 отделяет ошибку карты от ошибки исполнения: гарантия относится к плану, построенному в момент Q , а не к замкнутому контуру управления.

Задача. Дано n калибровочных сцен с известной истиной. Требуется найти для каждого класса запас $\hat{r}_k \in [0, \infty]$, такой что для новой сцены

$$\mathbb{P}(\text{любой путь с } \text{dist}(\gamma, A_\lambda(k)) > d + \hat{r}_k \text{ безопасен по классу } k) \geq 1 - \alpha, \quad (3.2)$$

и запас возможно меньше. Вероятность берётся по калибровочным сценам, новой сцене и ошибкам в них. Значение $\hat{r}_k = \infty$ (отказ) выполняет (3.2) тривиально: никакой путь не допускается. Запас сужает свободное пространство, поэтому меньший запас означает больше решаемых задач.

Допущение 2 (обменяемость). Пары (Ω_i, ξ_i) , $i = 1, \dots, n+1$, из сцены и реализации ошибок восприятия и позы в ней обменяемы, а детектор, построение карты, порог λ и $R_{\max}$ зафиксированы до калибровки.

Это выполняется, например, если сцены и ошибки в них независимы и одинаково распределены. Модель ошибок детектора и оценщика позы не нужна.

4. Метод

Определение 1 (расстояние промаха). След $\hat{F}_k$ представлен центрами клеток, в которые попадают точки истинных объектов класса k , перенесённые в систему планировщика; клетки за краем карты сохраняются. Для сцены и класса k

$$s_k = \min\{R_{\max}, h(\hat{F}_k, A_\lambda(k))\}, \quad h(X, Y) = \max_{x \in X} \min_{y \in Y} \|x - y\|, \quad (4.1)$$

где h — направленное расстояние Хаусдорфа. Если объектов класса в сцене нет, $s_k = 0$; если область пуста, $s_k = R_{\max}$.

Промех — расстояние от самой дальней точки истинного объекта до того, что нарисовано на карте (рис. 2). Пропущенный или перепутанный объект даёт большой промах, недорисованный — промах на величину недорисованной части, сдвиг карты — промах порядка сдвига, а поворот ещё и с плечом:

дальние от робота объекты смещаются сильнее. Промах считается один на сцену: клетки, кадры и объекты одной сцены сильно зависимы, и считать их отдельными примерами нельзя (допущение 2).

Калибровка. Пусть $s^{(1)} \leq \dots \leq s^{(n)}$ — упорядоченные промахи калибровочных сцен для класса k и $m = \lceil (n+1)(1-\alpha) \rceil$. Запас

$$\hat{r}_k = s^{(m)}, \quad \text{если } m \leq n \text{ и } s^{(m)} < R_{\max}; \quad \hat{r}_k = \infty \text{ иначе (отказ)}. \quad (4.2)$$

При $n = 13$ и $\alpha = 0,1$ ранг $m = 13$, то есть запас равен наибольшему из калибровочных промахов. Калибровка ведётся отдельно по классам, чтобы ненадёжный класс не раздувал запас остальных.

Утверждение 1. При допущениях 1 и 2

$$\mathbb{P}(\hat{r}_k = \infty \text{ или } s_k(\Omega_{n+1}) \leq \hat{r}_k) \geq \frac{m}{n+1} \geq 1 - \alpha,$$

и запас $\hat{r}_k$ удовлетворяет (3.2) для путей по центрам клеток.

Доказательство. По обменности ранг $s_k(\Omega_{n+1})$ среди $n+1$ промахов равномерно распределён; совпадения значений только помогают. Поэтому $\mathbb{P}(s_k(\Omega_{n+1}) \leq s^{(m)}) \geq m/(n+1)$ [4], а при отказе событие выполнено. Пусть $\hat{r}_k < \infty$ и $s_k \leq \hat{r}_k$. Тогда для любой точки $y \in \hat{F}_k$ найдётся $a \in A_\lambda(k)$ с $\|y - a\| \leq \hat{r}_k$, и для точки пути x с $\text{dist}(x, A_\lambda(k)) > d + \hat{r}_k$ по неравенству треугольника $\|x - y\| \geq \|x - a\| - \|a - y\| > d$. $\square$

Гарантия не зависит от планировщика: от него зависит только, найдёт ли он путь в суженном свободном пространстве. Она относится к центрам клеток. Для непрерывного следа и непрерывного движения между центрами расстояние может оказаться меньше d не больше чем на $\sqrt{2} \Delta \approx 7$ см (по $\Delta/\sqrt{2}$ на представление следа и на отрезок пути). Гарантия покласовая: для миссии с несколькими запретными классами $\mathcal{K}_m$ по неравенству Буля все классы покрыты с вероятностью не ниже $1 - |\mathcal{K}_m| \alpha$. Она маргинальна: усреднена по калибровочным выборкам, и при $n = 13$ покрытие отдельной выборки распределено как Beta(13, 1) со средним 0,93 и 10-м перцентилем 0,84 [4].

Сравниваемые калибровки. Варианты отличаются областью и тем, по каким промахам считается запас:

- *без калибровки:* область $A_{\lambda_0}(k)$, запас 0;
- *только метки:* промах (4.1) карты детектора при точных позах ($E_t \equiv I$), запас $\hat{r}_k^{\text{lab}}$;
- *только поза:* промах карты с эталонными метками, построенной по позам с дрейфом, запас $\hat{r}_k^{\text{pose}}$;
- *сумма:* $\hat{r}_k^{\text{lab}} + \hat{r}_k^{\text{pose}}$, оба на уровне α ;
- *совместный* (наш метод): промах карты детектора с дрейфом, запас $\hat{r}_k^{\text{joint}}$;
- *только геометрия:* областью класса считаются все занятые клетки ($\lambda = 0$), запас — квантиль промаха до них на карте с дрейфом. Это аналог раздувания карты занятости [6]: гарантия без семантики;
- *множества меток* по [5]: мера несоответствия сцены — худшее $1 - p_j(k)$ по клеткам истинного следа (∞ , если клетка не занята), $\hat{\eta}$ — её конформный квантиль; запретны клетки с $p_j(k) \geq 1 - \hat{\eta}$, запаса в метрах нет. У авторов максимум берётся по всем наблюдаемым клеткам и всем классам, включая «свободно»; наше ограничение следом может только уменьшить меру.

Первые пять вариантов используют одну область $A_{\lambda_0}(k)$ с порогом $\lambda_0 = 0,05$, выбранным на отдельной сцене. Варианты без запаса считаются покрывшими сцену, если промах не больше одной клетки, — это в их пользу.

Утверждение 2. Пусть для новой сцены

$$s_k \leq s_k^{\text{lab}} + s_k^{\text{pose}}, \quad (4.3)$$

где слагаемые — промахи вариантов «только метки» и «только поза» той же сцены. Тогда $\mathbb{P}(s_k \leq \hat{r}_k^{\text{lab}} + \hat{r}_k^{\text{pose}}) \geq 1 - 2\alpha$, а не $1 - \alpha$.

Доказательство. Каждый запас не покрывает свой промах с вероятностью не больше α ; по неравенству Буля оба покрывают с вероятностью не ниже $1 - 2\alpha$, и тогда по (4.3) $s_k \leq \hat{r}_k^{\text{lab}} + \hat{r}_k^{\text{pose}}$. $\square$

Условие (4.3) из геометрии не следует. По неравенству треугольника $s_k \leq s_k^{\text{lab}} + h(E_Q A^0, A)$, где A^0 — область карты детектора при точных позах: второе слагаемое — сдвиг *предсказанной* области. Вариант «только поза» измеряет другое — промах эталонной карты, как сделал бы инженер, отлаживающий локализацию отдельно от восприятия. На наших данных (4.3) нарушается в части реализаций (разд. 6.9). Распределение риска $\alpha/2 + \alpha/2$ дало бы $1 - \alpha$ [17], но требует $n \geq 2/\alpha - 1$, то есть 19 калибровочных сцен при $\alpha = 0,1$. Где окажется покрытие суммы, решает неизвестная зависимость двух ошибок; совместный запас от неё не зависит.

Миссии. Робот радиуса 0,2 м едет от старта до цели. Запретная зона класса — центры клеток на расстоянии не больше $d + \hat{r}_k$ от области класса; при отказе класса используется запасной сертификат «только геометрия». Путь ищется алгоритмом Дейкстры на 8-связной сетке. Он полон на графе сетки, поэтому «путь не найден» означает, что пути по свободным клеткам нет. Путь *опасен*, если его центр клетки ближе d к центру клетки истинного запретного объекта в системе планировщика. Путь *сталкивается*, если проходит ближе $0,2 - \Delta$ м к истинному препятствию: карта препятствий не калибруется, и сдвиг на одну клетку столкновением не считается. Миссия *успешна*, если путь найден, не опасен и не сталкивается. Кратчайший путь проверяет гарантию лишь вдоль одной линии, поэтому мы считаем и худший случай по всем планировщикам: есть ли клетка ближе d к истинному объекту, достижимая от старта без входа в запретную зону. Тот же планировщик на истинной карте даёт оракул.

Гипотезы. Обозначим $\text{Cov}(r)$ левую часть (3.2).

H1. Запас «только метки» даёт $\text{Cov} < 1 - \alpha$, когда дрейф сравним с ошибкой меток.

H2. Запас «только поза» даёт $\text{Cov} < 1 - \alpha$, пока дрейф меньше ошибки меток.

H3. Совместный запас не больше суммы: $\hat{r}_k^{\text{joint}} \leq \hat{r}_k^{\text{lab}} + \hat{r}_k^{\text{pose}}$.

H4. Метрика качества карты mIoU слабо связана с безопасностью миссий.

Покрытие совместного варианта не гипотеза: оно следует из утверждения 1, и его измерение проверяет реализацию.

5. Экспериментальная установка

Данные. 22 сцены ReplicaCAD [21] из OSMa-Bench [2]: RGB, глубина, эталонная семантика и позы камеры, 640×480 , освещение *baseline*, каждый 8-й кадр (около 140 кадров на сцену). На сцене *art_0* приняты все решения о методе: запретные классы, порог λ_0 , параметры карты; в калибровку и тест она не входит.

Восприятие и карта. Детектор YOLO-World v2-s [22] с 98 текстовыми запросами — словарём ReplicaCAD без стен, пола и потолка. Внутри рамки остаются пиксели, глубина которых отличается от медианной глубины рамки не больше чем на 0,25 м. Точки проецируются в сетку с $\Delta = 5$ см; занятыми считаются клетки с точками на высоте 0,1–1,8 м. Наблюдения сливаются усреднением [9]. Запретные классы — растение, велосипед и тумба под ТВ: хрупкие или дорогие предметы, которые есть во всех сценах. Истинный след объекта — связанная компонента занятых клеток, где не меньше двух точек его класса, размером от 8 клеток.

Ошибка позы. Синтетический дрейф повторяет каждое относительное движение истинной траектории с шумом, пропорциональным пройденному пути и углу поворота. Кроме точной позы L0 есть пять уровней дрейфа L1–L5, заданных на сцене *art_0*: L1–L3 — по целевой ATE (absolute trajectory error, среднеквадратичная ошибка положения по траектории), L4–L5 — по конечному дрейфу в процентах пути. На оценочных сценах, где пути короче, медианная ATE равна: L1 0,4 см, L2 2 см, L3 7 см, L4 45 см, L5 2,7 м. На каждый уровень — 10 реализаций. Реальная ошибка позы — RGB-D-одометрия Open3D [23, 24] кадр к кадру на каждом 2-м кадре, без замыканий циклов, с плоским ограничением наземного робота; её параметры не подбирались по истине.

Протокол покрытия. $\alpha = 0,1$, если не указано иное; $R_{\text{max}} = 3$ м. Остальные 21 сцена 200 раз случайно делятся на 13 калибровочных и 8 тестовых; если разбиений не больше 2000 (например, 19 и 2 при $\alpha = 0,05$), перебираются все. Калибровочная сцена даёт одну случайную реализацию дрейфа, тестовая — все. *Покрытие* — доля тестовых реализаций, где промах не больше запаса, усреднённая по разбиениям; отказ, как и в утверждении 1, засчитывается как выполненная пустая гарантия. Отдельно приводятся доля разбиений с отказом и покрытие среди разбиений, где сертификат выдан. Так как разбиения случайны внутри одних и тех же 21 сцены, сцены в них обменяемы по построению, и покрытие совместного варианта в среднем не ниже $1 - \alpha$ при любых данных (с точностью до случайного выбора

реализаций). Это проверка реализации; содержательны размер запаса, доля отказов и поведение вариантов без гарантии.

Задачи. Старт и цель находятся не ближе 1,5 м к запретным объектам и не ближе 3 м друг к другу. Трудные задачи «проезд мимо» отобраны так, что кратчайший путь по одной лишь геометрии проходит ближе 0,5 м к растению или велосипеду: безопасный объезд есть, а планировщик, недооценивающий объект, срезает угол. Таких задач 233 в 15 сценах. Случайные задачи не отбираются, по 20 на сцену (420 задач). Запасы для сцены калибруются по остальным 20 сценам ($m = 19$, второй по величине промах). В основной конфигурации миссий запретные классы — растение и велосипед, тумба считается обычным препятствием; результаты для трёх классов приведены отдельно.

Оба выбора сделаны после первых прогонов. Первая версия задач (цель в 0,7–1,2 м от запретного объекта) оказалась вырожденной: откалиброванная запретная зона накрывала саму цель. Тумба исключена из основной конфигурации после того, как выяснилось, что она отказывается. Гарантия покрытия от этих решений не зависит, но доли решённых задач нужно читать с этой оговоркой.

6. Результаты

6.1. Покрытие при дрейфе позы

Таблица 1: Покрытие и медианный запас $\hat{r}$ по 200 разбиениям 13/8, $1 - \alpha = 0,9$. Медианная АТЕ: L2 — 2 см, L3 — 7 см, L4 — 45 см. Отказ засчитан как покрытие; $\dagger$ — вариант отказывается в половине разбиений или чаще, приведён медианный запас остальных. Запас «только геометрии» отсчитывается от всех занятых клеток

Класс	Калибровка	L0		L2		L3		L4	
		покр.	$\hat{r}$, м	покр.	$\hat{r}$, м	покр.	$\hat{r}$, м	покр.	$\hat{r}$, м
велосипед	без калибровки	0,00	0	0,00	0	0,01	0	0,01	0
	множества меток	1,00	0	0,73	0	0,34	0	0,18	0
	только геометрия	1,00	0,00	0,96	0,10	0,94	0,15	0,93	0,65
	только метки	0,93	0,75	0,93	0,75	0,92	0,75	0,76	0,75
	только поза	0,00	0,00	0,06	0,10	0,27	0,21	0,82	0,85
	сумма	0,93	0,75	0,98	0,82	0,99	0,93	0,97	1,61
растение	без калибровки	0,00	0	0,00	0	0,00	0	0,00	0
	множества меток	1,00	0	0,41	0	0,10	0	0,03	0
	только геометрия	1,00	0,00	0,95	0,11	0,94	0,22	0,93	0,71
	только метки	0,93	0,85 $\dagger$	0,96	0,85 $\dagger$	0,94	0,85 $\dagger$	0,86	0,85 $\dagger$
	только поза	0,00	0,00	0,01	0,14	0,13	0,25	0,85	1,37
	сумма	0,93	0,85 $\dagger$	0,98	0,96 $\dagger$	0,96	1,07 $\dagger$	0,95	2,06 $\dagger$
совместный		0,93	0,75	0,94	0,75	0,93	0,75	0,92	1,23




Рис. 1: Растение и велосипед (среднее по двум классам): а) покрытие; б) медианный запас; в) совместный запас: доля разбиений, где сертификат выдан (сплошные линии), и покрытие среди них (штриховые)

Карта без калибровки почти никогда не накрывает истинный объект целиком: детектор обрезает края (табл. 1). Множества меток дают покрытие 1,00 без дрейфа лишь потому, что их порог $1 - \hat{r}$ равен нулю: во всех 21 сцене у каждого класса есть занятая клетка следа без единого наблюдения своего класса, мера несоответствия равна 1, и запретной становится любая занятая клетка, как у варианта «только

геометрия». Запаса в метрах у множеств меток нет, и дрейф в 2 и 7 см снижает покрытие велосипеда до 0,73 и 0,34. Калибровать их на картах с дрейфом бесполезно: при L1–L3 в 79–100 % реализаций растения и велосипеда какая-то клетка следа на карте не занята, и калибровка отказывается.

Запас «только метки» держится, пока дрейф меньше ошибки меток, и при 45 см падает до 0,76 для велосипеда; 90 %-интервал бутстрепа по сценам 0,67–0,82 лежит ниже цели (H1). Для растения падение слабее (0,86), и интервал 0,59–0,90 лишь касается цели. Запас «только поза» не видит ошибок детектора: при дрейфе до 7 см его покрытие не выше 0,27 (H2). Сумма двух запасов переплачивает: при 45 см совместный запас меньше её на 23–25 % (1,23 против 1,61 м для велосипеда, 1,54 против 2,06 м для растения), при дрейфе 0,4–7 см — на 6–25 % (H3).

Совместный запас держит 0,92–0,94 для растения и велосипеда на уровнях L0–L4, как и должно быть по построению; содержательны цена и отказы (рис. 1). Велосипед на L0–L4 сертифицируется всегда, его запас растёт с 0,75 до 1,23 м. Растение в одной сцене из 21 детектор не находит вовсе (промах 3 м). При 13 калибровочных сценах запас равен максимуму, и без дрейфа класс отказывается всякий раз, когда эта сцена попадает в калибровку, — в 63 % разбиений, около 13/21; при дрейфе промах этой сцены иногда меньше максимума, и отказов 24–59 %. Когда сертификат выдан, худшие сцены чаще оказываются в тесте, и покрытие среди таких разбиений 0,81–0,92 — ниже номинала, что маргинальная гарантия допускает. Тумба под ТВ, которую детектор в трёх сценах уверенно принимает за скамейку, ковёр или кровать, отказывается в 75–95 % разбиений (о роли словаря — в разд. 6.5); при L5 все классы отказываются в 97–100 %. Оба класса миссии сразу покрыты в 85–87 % тестовых реализаций, в согласии с границей $1 - 2\alpha$.

6.2. Миссии




Рис. 2: Трудная задача при дрейфе L2 в системе координат планировщика. Красное — истинные растение и велосипед, линия — граница запретной зоны. Без калибровки зона не накрывает обрезанный край растения, и путь проходит ближе 0,5 м к нему (чёрные точки)

Таблица 2: Трудные задачи (растение и велосипед, 233 задачи в 15 сценах, при дрейфе — по 5 реализаций): доля задач с найденным путём, число опасных путей из найденных, доля успешных миссий

Калибровка	L0			L2			L3		
	путь	опасн.	успех	путь	опасн.	успех	путь	опасн.	успех
без калибровки	0,99	126/231	0,45	0,97	656/1130	0,41	0,89	560/1032	0,39
множества меток	0,27	0/62	0,27	0,28	29/323	0,25	0,21	65/244	0,15
только геометрия	0,27	0/62	0,27	0,12	0/139	0,12	0,05	0/56	0,05
только метки	0,32	0/74	0,32	0,31	2/364	0,31	0,30	0/347	0,30
только поза	0,99	126/231	0,45	0,95	267/1112	0,72	0,81	190/941	0,62
сумма	0,32	0/74	0,32	0,31	2/359	0,30	0,27	0/315	0,27
совместный	0,32	0/74	0,32	0,31	2/364	0,31	0,30	0/353	0,30
оракул	1,00	0/233	1,00	0,98	0/1140	0,98	0,99	0/1148	0,99

На трудных задачах планировщик без калибровки находит путь почти всегда, но 54–58 % его путей опасны: он идёт вплотную к обрезанному краю объекта (рис. 2, табл. 2). У совместного запаса, суммы и запаса «только метки» опасны 0–2 пути из 74–384, а опасная клетка достижима хоть для какого-то планировщика в 0–3 % реализаций против 96–100 % у карты без калибровки. Запас «только поза» при малом дрейфе почти нулевой (20–55 % опасных путей). Множества меток безопасны без дрейфа, но при 2 и 7 см опасны 9 и 27 % их путей.

Цена — путь находится лишь в 30–32 % трудных задач против 97–100 % на истинной карте. Поэтому по доле успешных миссий планировщик без гарантии выигрывает (39–45 % против 29–32 %): около половины его путей безопасны случайно. Гарантия ограничивает риск, а не повышает успех. Семантика окупается: вариант «только геометрия» находит путь в 27 % трудных задач без дрейфа и в 5–15 % при дрейфе, в 2–6 раз реже совместного. На случайных задачах совместный запас даёт 78 % успешных миссий без дрейфа и 68 % при 7 см, без опасных путей; без калибровки успешны 93 и 80 %, но 7–8 % путей опасны; «только геометрия» — 43 и 9 %. Столкновения с препятствиями гарантия не покрывает; при 7 см они доходят до 3–5 % миссий у вариантов, пути которых идут вдоль стен. С тумбой как третьим запретным классом (303 задачи в 18 сценах) она почти всегда переходит на запасной сертификат, и совместный вариант находит путь лишь в 6–23 % задач.

6.3. Сравнение с множествами меток

Таблица 3: Случайные задачи (420 в 21 сцене): доля успешных миссий; * — есть опасные пути

Словарь	$1 - \alpha$	Дрейф	множества меток	только геометрия	совместный	без калибровки	оракул
закрытый	0,95	известна	0,43	0,43	0,42	0,93*	1,00
		L2	0,39*	0,19	0,61	0,89*	0,97
		L3	0,31*	0,07	0,50	0,80*	0,97
закрытый	0,90	известна	0,43	0,43	0,78	0,93*	1,00
		L2	0,39*	0,21	0,74	0,89*	0,97
		L3	0,31*	0,10	0,67	0,80*	0,97
открытый	0,95	известна	0,43	0,43	0,42	0,93*	1,00
		L2	0,39*	0,19	0,46	0,88*	0,97
		L3	0,31*	0,07	0,34	0,80*	0,97
открытый	0,90	известна	0,43	0,43	0,78	0,93*	1,00
		L2	0,39*	0,23	0,74	0,88*	0,97
		L3	0,31*	0,09	0,68	0,80*	0,97

Успех миссий у [5] (98,36 %) получен в другой постановке: открытые площадки, известная поза, пять классов, режим исследования. Поэтому мы сравниваем методы на наших сценах и случайных задачах по схеме 2×2 : закрытый словарь (из 98 текстовых эмбедингов детектора оставлены пять) или открытый и их уровень $1 - \alpha = 0,95$ или наш 0,9, каждый при известной позе и при дрейфе 2 и 7 см (табл. 3). Режим исследования не воспроизводился.

Множества меток дают одно и то же во всех четырёх условиях: их порог всегда нулевой, и зона та же, что у «только геометрии» без дрейфа (0,43). В их условиях совместный запас с ними совпадает (0,42): при 20 калибровочных сценах и $\alpha = 0,05$ запас растения равен наибольшему промаху, растение отказывается в 95 % сцен и переходит на ту же зону. При известной позе словарь ничего не меняет, разницу создаёт уровень риска: при $1 - \alpha = 0,9$ совместный запас успешен в 78 % миссий против 43 % при любом словаре. При дрейфе и $\alpha = 0,05$ закрытый словарь помогает совместному запасу (0,61 и 0,50 против 0,46 и 0,34): растение реже отказывается. При дрейфе множества меток пропускают опасные пути (0,4 и 1,1 % миссий при 2 и 7 см; опасная клетка достижима в 56–60 % реализаций), а совместный запас остаётся без опасных путей и успешнее: 0,46–0,74 и 0,34–0,68 против 0,39 и 0,31. Более грубая сетка не спасает множества меток: на сетках 25, 50 и 100 см их порог тоже нулевой, а запретная зона растёт с 64 % свободного пространства при 5 см до всего пространства при 1 м (в этом опыте при $\alpha = 0,05$ и калибровке по остальным 20 сценам совместный запас для растения отказывается на всех сетках, для велосипеда — от 50 см). Множество меток может сказать только «эта клетка может быть растением»; расстояние говорит «растение где-то рядом», и это полезно, когда детектор теряет края объектов.

Наши абсолютные доли успеха ниже опубликованных у Sundarsingh и др. (98,36 %), но не из-за метода: их же метод на наших сценах даёт 43 %. Разница в постановке — просторные площадки с

Таблица 4: Опубликованные результаты ближайших работ и те же методы на наших данных (случайные задачи, известная поза). Числа в разных условиях напрямую не сравнимы: сравнимы только столбцы «на наших данных»

Работа	Их условия и результат	Тот же метод на наших дан- ных	Совместный запас
Sundarsingh и др. [5]	площадки 70×25 м, сетка 1 м, 5 классов, режим исследования; успех миссий 98,36 % при 95 %, без учёта неопределённости 65,57 % (табл. I)	множества меток: 43 % при 95 и 90 %; при дрейфе 7 см 31 % и опасные пути	42 % при 95 %, 78 % при 90%; при 7 см 34–68 % без опасных путей
Perceive Confidence [6]	With помещения, рамки 3DETR, робот, 15 сред: столкновений 20 % против 66,7 %, цель 53,3 % против 33,3 % (табл. I)	«только геометрия»: 43 % без дрейфа, 9 % при 7 см	78 и 68 %

крупной сеткой и режимом исследования против загромождённых квартир, где детектор обрезает края объектов.

6.4. Цена гарантии

Таблица 5: Уровень риска при дрейфе L3: покрытие и медианный запас совместного варианта, доля разбиений с отказом для растения, доля трудных задач с путём и доля успешных случайных миссий. Покрытие — по разбиениям 13/8 (при $\alpha = 0,05$ — по всем 210 разбиениям 19/2), миссии — с калибровкой по 20 сценам

α	покрытие		$\hat{r}$, м		отказ	трудные: путь		случайные: успех	
	раст.	велос.	раст.	велос.	раст.	совм.	оракул	совм.	оракул
0,05	0,95	0,95	0,85	0,76	0,70	0,10	0,99	0,34	0,97
0,10	0,93	0,93	0,80	0,75	0,52	0,30	0,99	0,68	0,97
0,20	0,86	0,86	0,74	0,70	0,00	0,31	0,99	—	—
0,30	0,72	0,72	0,60	0,50	0,00	0,31	0,99	0,71	0,97

Повышение риска почти не добавляет решаемых задач (табл. 5). С $\alpha = 0,1$ до 0,3 совместный запас уменьшается на 0,20–0,25 м, доля трудных задач с путём растёт с 30 до 31 %, успешных случайных — с 68 до 71 %, а доля реализаций с достижимой опасной клеткой — с 3 до 20–27 %, вслед за α . При $\alpha = 0,05$ запас по 20 сценам равен наибольшему промаху, в 73 % реализаций какой-то класс переходит на запасной сертификат, и путь находится лишь в 10 % трудных задач.

Запас задаёт наихудшая калибровочная сцена, пока $n < 2/\alpha - 1$. При 19 калибровочных сценах ранг становится $n - 1$, и одна сцена с пропущенным растением больше не заставляет отказываться: доля отказов растения падает с 63 до 0 % без дрейфа и с 59 до 11 % при 45 см, а запас велосипеда при 45 см — с 1,23 до 1,00 м. Лучшие маски помогают лишь частично: MobileSAM [25], получающий на вход рамки детектора, снижает медианный промах велосипеда без дрейфа с 0,43 до 0,05 м, но наихудшая сцена сохраняет 0,75 м, и запас велосипеда без дрейфа не меняется; при 45 см он уменьшается с 1,23 до 1,06 м. Запас растения без дрейфа уменьшается с 0,85 до 0,61 м, но при 45 см растёт с 1,54 до 1,86 м. Порог $\lambda_0 = 0,05$ выбран на отладочной сцене; при $\lambda_0 = 0,02$ запас немного меньше (велосипед при 45 см 1,08 против 1,23 м), при 0,1–0,2 растение отказывается в 65–100 % разбиений, а $\lambda_0 = 0$ даёт вариант «только геометрия».

6.5. Что снижает цену гарантии

Больше калибровочных сцен помогает, как показано выше: при 19 сценах одна сцена с пропущенным объектом перестаёт определять запас. Новых сцен того же семейства в готовом виде нет: для OSMa-Bench++ опубликован конвейер генерации, а не данные.

Детектор. Худший промах растения дают два маленьких горшка (по 13–15 клеток) в одной сцене: один основной детектор принимает за навесной шкаф, другого не видит вовсе. Самая большая модель того же семейства, YOLO-World v2-x, и YOLOE-v8-S [26] (оба с тем же словарём) находят растение: худший промах падает с 3 до 0,71–0,72 м, отказы растения почти исчезают, запас без дрейфа уменьшается с 0,85 до 0,71–0,72 м (табл. 6). Но у каждого детектора нашёлся свой целиком пропущенный класс. YOLO-World v2-x ещё увереннее путает тумбу и чаще отмечает растения и велосипеды там, где их нет (площадь их областей больше на 32 и 10 %); без дрейфа он находит путь в 41 % трудных задач

Таблица 6: Детекторы с одним словарём из 98 классов, их объединение (в клетке — максимум, среднее или второе по величине из трёх долей класса) и каскад с проверкой CLIP: медианный запас совместного варианта (м) и доля разбиений с отказом, доля трудных задач с путём и доля успешных случайных миссий

Детектор	$\hat{r}$ / отказ, L0			$\hat{r}$ / отказ, L4		трудные: путь		случайные: успех	
	растение	велосипед	тумба	растение	велосипед	L0	L3	L0	L3
YOLO-World v2-s	0,85 / 0,63	0,75 / 0,00	2,62 / 0,95	1,54 / 0,59	1,23 / 0,00	0,32	0,30	0,78	0,68
YOLO-World v2-x	0,71 / 0,00	0,80 / 0,00	— / 1,00	1,56 / 0,10	1,11 / 0,00	0,41	0,23	0,83	0,64
YOLOE-v8-S	0,72 / 0,00	0,71 / 0,85	1,72 / 0,64	1,68 / 0,05	1,17 / 0,83	0,16	0,07	0,45	0,20
ансамбль, максимум	0,71 / 0,00	0,75 / 0,00	1,40 / 0,00	1,42 / 0,05	1,08 / 0,00	0,60	0,22	0,87	0,64
ансамбль, среднее	0,71 / 0,00	0,80 / 0,00	1,10 / 0,64	1,56 / 0,05	1,11 / 0,00	0,41	0,31	0,83	0,68
ансамбль, второе	0,71 / 0,00	0,90 / 0,00	1,33 / 0,99	1,68 / 0,05	1,23 / 0,00	0,33	0,31	0,78	0,69
каскад с CLIP	1,06 / 0,99	0,75 / 0,00	1,89 / 0,99	2,38 / 0,99	1,12 / 0,00	0,19	0,04	0,39	0,10

вместо 32 %, но при 7 см — в 23 % вместо 30 %. YOLOE реже путает тумбу (одна сцена с подменой вместо трёх), но в двух сценах целиком теряет велосипед, и велосипед отказывается в 83–85 % разбиений; в миссиях он почти всегда уходит на запасной сертификат, и путь находится лишь в 7–16 % трудных задач. Узкое место не исчезает, а переходит между классами: пока калибровочных сцен мало, запас определяет наихудший объект любого класса.

Ансамбль и каскад. Раз у каждого детектора свой пропущенный класс, их можно объединить. Три карты строятся по одним и тем же точкам, и в каждой клетке берётся максимум, среднее или второе по величине из трёх долей класса; отчитываемся по всем трём правилам, не выбирая лучшее по тестовым сценам. Максимум снимает отказы всех трёх классов при дрейфе до 45 см: растение отказывается в 0–5 % разбиений вместо 24–63 %, тумба — в 0 % вместо 74–95 %; запас без дрейфа 0,71 м для растения, 0,75 м для велосипеда и 1,40 м для тумбы, покрытие среди сертификатов 0,92–0,94 (табл. 6). Цена — области растения и велосипеда больше на 12–41 % (по пяти сценам) и втрое больше вычислений. В миссиях путь находится в 60 % трудных задач без дрейфа вместо 32 % и в 47 % при 2 см вместо 31 %, а при 7 см — в 22 % вместо 30 %: решаемость собирается по сценам, и почти всю разницу при 7 см даёт одна сцена, где ансамбль наконец видит растение и закрывает проход. Среднее оставляет отказы тумбы (60–64 %), но и не проигрывает при 7 см (41, 36 и 30 % трудных задач). Второе по величине, то есть согласие двух детекторов, снова теряет тумбу (отказ 97–99 %), увеличивает запас велосипеда до 0,90 м и в миссиях не лучше одного детектора (33, 32 и 30 % трудных задач). Каскад, в котором объединённые находки проверяет CLIP [27] по вырезке рамки (98 классов плюс «стена», «пол», «потолок»; порог подобран на отладочной сцене), проигрывает: проверка выбрасывает растение целиком в трёх тестовых сценах и тумбу в трёх, и оба класса отказываются в 98–99 % разбиений; путь находится лишь в 19, 12 и 4 % трудных задач. Явное голосование по кадрам («класс в клетке видели не меньше m кадров») уже на отладочной сцене уменьшает ложную площадь ценой роста промахов (велосипед 0,21 → 0,29 м при $m = 2$). Гарантия платит за наихудший промах, поэтому выигрывает полнота: правило «максимум» лучше среднего, а среднее лучше согласия двух; проверка, которая может только убирать находки, только добавляет промахов. Сама идея ансамбля возникла после того, как мы увидели пропуски детекторов на этих сценах, поэтому выигрыш может быть оптимистичным.

Словарь. Подмену тумбы создают конкуренты в словаре. С закрытым словарём из пяти классов тумба сертифицируется во всех разбиениях, но без конкурентов тумбой называются и скамейки, и кровати, её область разрастается, и миссии с тремя запретными классами решаются ещё хуже: путь находится в 5–8 % трудных задач против 6–23 % с открытым словарём. Объединить класс с его частыми «двойниками» честно нельзя: на отладочной сцене тумбу путают с экраном и монитором, а на тестовых — со скамейкой, ковром и кроватью, а подбирать двойников по тестовым сценам значило бы подгонять результат.

Область класса. Дорастивание области по соседним занятым клеткам на 15 или 30 см, чтобы закрыть обрезанные края, почти не меняет запас (без дрейфа совсем, при 45 см на 0,07–0,14 м), а площадь области растёт в 2–4 раза: худшие промахи дают не края, а целые объекты.

Калибровка. Иерархическая калибровка [28] по всем 10 реализациям дрейфа каждой калибровочной сцены вместо одной случайной убирает лотерею: разброс запаса по разбиениям при 45 см падает в 3–4 раза (у велосипеда стандартное отклонение 0,49 против 0,18 м), а медианный запас честно растёт (1,24 против 1,50 м). Одна гарантия сразу на оба класса — конформный квантиль максимума двух про-

махов — даёт покрытие обоих 0,92–0,94 вместо 0,88–0,92 при покласовой калибровке, ценой среднего запаса больше на 0,03–0,26 м. Более строгая РАС-форма [29] — «покрытие не ниже 0,9 с вероятностью 0,9 по калибровочной выборке» — при 20 калибровочных сценах невозможна (нужно не меньше 22), а «не ниже 0,8 с вероятностью 0,9» даёт ту же 19-ю порядковую статистику, что и маргинальная гарантия при $\alpha = 0,1$. Цену гарантии эти приёмы не снижают, но делают её честнее.

Условный запас мог бы быть меньше там, где ошибка мала. Самый доступный роботу признак — длина пройденного пути — бесполезен: его ранговая корреляция с промахом совместной карты от $-0,09$ до $0,15$ на уровнях L2–L4. Целиком пропущенный объект не оставляет следа на карте, и никакой признак карты его не предскажет. Взвешенное конформное предсказание [19] ограничивает потерю покрытия на непохожих сценах, но требует оценить, насколько они непохожи; на двух сценах HM3D этого не проверить.

6.6. Риск вместо отказа




Рис. 3: Доля задач, для которых найден путь с сертифицированным риском не выше a (чёрные линии), и доля задач с таким путём, оказавшимся опасным (серые), при разном дрейфе; пунктир — a

Отказ — грубый ответ: сертификат либо выдан на уровне α , либо нет. Вместо этого можно строить путь с запасом из сетки 0–2 м и сообщать для него риск. Если путь опасен для класса k , то промах сцены s_k больше зазора пути c_k (расстояние до области класса минус d). Поэтому величина $\rho_k(c) = (1 + \#\{i : s_{i,k} \geq \min(c, R_{\max})\}) / (n + 1)$ по калибровочным промахам — конформное р-значение, и $\mathbb{P}(\text{путь опасен и } \rho_k \leq a) \leq a$, даже если путь выбран по тестовой карте. Нестрогое неравенство и обрезка зазора на $R_{\max}$ нужны потому, что промахи обрезаны на 3 м. Для двух классов риск делится поровну: путь сертифицирован на уровне a , если $\rho_k \leq a/2$ для каждого класса. Для каждого a берётся наименьший запас из сетки, путь которого сертифицирован.

Решаемость при этом не растёт (рис. 3). При $a = 0,2$, то есть $\alpha = 0,1$ на класс, сертифицированный путь есть у 27–29 % трудных и 70–77 % случайных задач — столько же, сколько у совместного запаса с $\alpha = 0,1$, как и следует из теории. Доля опасных путей среди сертифицированных не выше 0–5,7 % и в сумме не превышает a . Зато вместо отказа робот получает путь с явным риском, и становится видна причина отказов: при 20 калибровочных сценах наименьший возможный риск на класс равен $1/21$, а одна сцена с пропущенным растением поднимает его до $2/21$, поэтому при $a = 0,1$ без дрейфа сертифицируется лишь 5 % случайных задач. На трудных задачах даже при $a = 1$ путь есть лишь в 39–46 % задач: кратчайшие объезды проходят через сами области классов.

6.7. Гарантия на миссии вместо гарантии на карту

Совместный запас обещает, что внутри запаса лежит каждый объект класса, в том числе тот, мимо которого не проходит ни один путь. Для робота важнее другое — доля миссий, в которых путь прошёл опасно близко. Её можно калибровать напрямую, контролем конформного риска [30] по запасу планировщика. Для запаса m из сетки 0–2 м потеря сцены $L_i(m)$ — доля её задач (по всем реализациям дрейфа), путь которых при этом запасе опасен; огибающая $\tilde{L}_i(m) = \max_{m' \geq m} L_i(m')$ делает потерю монотонной. Наименьший запас, при котором $\frac{n}{n+1} \cdot \frac{1}{n} \sum_i \tilde{L}_i(m) + \frac{1}{n+1} \leq a$, даёт $\mathbb{E}[L_{\text{тест}}] \leq a$ для обменяемой тестовой сцены. Калибруем по остальным сценам с задачами на каждом уровне дрейфа отдельно и проверяем на отложенной.

Таблица 7: Гарантии разной силы на одних и тех же задачах: доля успешных миссий при точной позе, 2 и 7 см и наибольшая по уровням доля опасных миссий. Совместный запас и риск пути гарантируют каждый путь, риск планировщика — ожидаемую долю опасных миссий в новой сцене; «по исполнению» — с учётом дрейфа во время движения (разд. 6.8)

Правило	Уровень	случайные задачи				трудные задачи			
		L0	L2	L3	опасн.	L0	L2	L3	опасн.
без калибровки	—	0,93	0,88	0,80	0,076	0,45	0,41	0,39	0,563
совместный запас	$\alpha = 0,1$ на класс	0,78	0,74	0,68	0,000	0,32	0,31	0,30	0,002
риск пути	$a = 0,2$	0,77	0,70	0,71	0,000	0,29	0,29	0,27	0,002
риск планировщика	$a = 0,05$	0,94	0,87	0,80	0,006	0,00	0,00	0,00	0,000
риск планировщика	$a = 0,1$	0,95	0,92	0,88	0,051	0,40	0,57	0,36	0,013
то же, по исполнению	$a = 0,1$	—	0,92	0,87	0,052	—	0,56	0,36	0,011
риск планировщика, ансамбль	$a = 0,05$	0,91	0,86	0,75	0,027	0,00	0,00	0,00	0,000
риск планировщика, ансамбль	$a = 0,1$	0,96	0,92	0,86	0,043	0,41	0,83	0,54	0,022

Гарантия здесь другая и слабее: ограничена ожидаемая доля опасных миссий, а не вероятность, что объект выйдет за запас, и отдельная сцена может оказаться опасной целиком. Зато пропуск, мимо которого не идут пути, больше не определяет запас. На случайных задачах при $a = 0,05$ успешны 94, 87 и 80 % миссий при точной позе, 2 и 7 см — почти столько же, сколько без калибровки (93, 88 и 80 %), но опасных не больше 0,6 % вместо 7–8 % (табл. 7); совместный запас даёт 78, 74 и 68 %. В худшей сцене опасны до 13 % миссий. При $a = 0,1$ успешных 88–95 %, опасных около 5 %, но в худшей сцене до 65 % — так выглядит гарантия на среднее. На трудных задачах сцен с задачами 15, поэтому $a = 0,05 < 1/(n+1)$ недостижимо, а при $a = 0,1$ путь находится в 40, 57 и 36 % задач вместо 30–32 % при не более 1,3 % опасных. Вместе с ансамблем детекторов (разд. 6.5) гарантия на миссии при $a = 0,1$ решает 41, 83 и 54 % трудных задач при не более 2,2 % опасных — лучшее сочетание из проверенных; на случайных задачах ансамбль немного хуже одного детектора (91, 86 и 75 % при $a = 0,05$) из-за больших ложных областей. Выбор между двумя гарантиями — вопрос требований: «ни один объект не выйдет за запас» или «в среднем не больше a опасных миссий».

6.8. Гарантия на время исполнения

Таблица 8: Пути, сертифицированные по плану ($a = 0,2$), при исполнении с продолжающимся дрейфом (20 исполнений на путь): отклонение от заданной траектории в процентах пройденного пути, доля задач с сертифицированным путём, доля опасных и задевших препятствие исполнений среди сертифицированных; справа — правило с запасом на исполнение

Дрейф	отклонение, % пути		сертификат по плану			с запасом на исполнение		
	медиана	95 %	путь	опасн.	столкн.	путь	опасн.	столкн.
L2, трудные	0,3	0,7	0,30	0,006	0,02	0,29	0,006	0,02
L3, трудные	0,8	2,1	0,31	0,000	0,03	0,23	0,000	0,02
L4, трудные	5,2	13,0	0,13	0,012	0,18	0,00	—	—
L2, случайные	0,2	0,6	0,72	0,000	0,06	0,72	0,000	0,06
L3, случайные	0,8	2,0	0,77	0,000	0,10	0,72	0,000	0,09
L4, случайные	5,2	12,5	0,52	0,000	0,18	0,21	0,000	0,15

Гарантия выше относится к плану в момент запроса (допущение 1). Чтобы проверить, что происходит при движении, робот проходит каждый путь примитивами траекторий съёмки (3 см вперёд или поворот на 2°), а его оценка позы продолжает дрейфовать по той же модели и с тем же уровнем, что и при построении карты; путь упрощается до опорных точек в пределах одной клетки. При 2 и 7 см отклонение от заданной траектории — 0,3 и 0,8 % пройденного пути в медиане и до 2 % в 95 % исполнений, и пути, сертифицированные по плану, остаются безопасными: опасных исполнений среди них не больше 0,6 % (табл. 8). При 45 см отклонение около 5 % пути: на трудных задачах 1,2 % сертифицированных путей становятся опасными при езде, а 18 % задевают препятствия — от них карта отступает лишь на радиус робота.

Формально план можно сертифицировать и на всё время движения. Если δ — наибольшее отклонение при исполнении, то путь опасен для класса k лишь при $s_k + \delta > c_k$. Отклонение на метр пути $u = \delta/L$ калибруем по исполнениям путей других сцен (конформный квантиль с уровнем $a/25$) и требуем $\rho_k(c_k - \hat{u}L) \leq (a - a/25)/2$; по неравенству Буля $\mathbb{P}(\text{опасно при исполнении и сертифицировано}) \leq a$.

Выборка исполнений здесь объединена по путям и предполагается обменяемой, тогда как ценовая часть сохраняет точную гарантию. При 2 и 7 см это почти ничего не стоит: $\hat{u} \approx 0,01$ и $0,03$, и доля сертифицированных случайных задач падает с 72 и 77 до 72 и 72 %. При 45 см $\hat{u} \approx 0,17$, и сертифицируется 21 % случайных задач вместо 52 % и ни одной трудной. Контроль риска планировщика с потерей «опасно при исполнении» даёт ту же гарантию без отдельной оценки отклонения: при $\alpha = 0,05$ успешны 87 и 80 % случайных миссий при 2 и 7 см (табл. 7). Столкновения с препятствиями гарантия не покрывает; при дрейфе в 45 см роботу нужна перелокализация по карте во время движения.

6.9. Когда сумма запасов недопокрывает




Рис. 4: Покрытие суммы отдельных запасов и совместного запаса в зависимости от доли сцен со сбоем локализации; $1 - \alpha = 0,7$, пунктир — граница $1 - 2\alpha$ для суммы

На синтетическом дрейфе сумма отдельных запасов только переплачивает, хотя условие (4.3) нарушается в 2–12 % реализаций растения и велосипеда при L1–L4 и в 11–26 % при L5. Чтобы увидеть недопокрытие, мы оставили реальные ошибки меток и заменили дрейф ценовой смесью: в b сценах из 21 происходит сбой локализации (реализации L5), в остальных дрейф пренебрежимо мал (L1). Сцены со сбоем выбираются там, где метки хуже всего, где лучше всего, или случайно; $\alpha = 0,3$, потому что при $\alpha = 0,1$ и 13 сценах любой сбой попадает в максимум; разбиений 1000. Если сбои совпадают с плохими метками, сумма переплачивает (0,74–0,82). Если они приходятся на сцены с хорошими метками, её покрытие опускается до 0,68–0,69 при цели 0,70 (14–24 % сцен со сбоем), при случайном расположении — до 0,66. Совместный запас даёт 0,69–0,74 при любом расположении, около ожидаемых $10/14 \approx 0,71$ (рис. 4). Недопокрытие небольшое; опыт показывает лишь, что граница $1 - 2\alpha$ не формальность и что положение суммы решает заранее неизвестное расположение сбоев.

6.10. Реальная одометрия и другие сцены

Таблица 9: Проверка упрощений: покрытие и медианный запас (m), $\alpha = 0,1$; $\dagger$ — вариант отказывается в половине разбиений или чаще, приведён запас остальных

Вариант	велосипед						растение					
	метки		сумма		совм.		метки		сумма		совм.	
	покр.	$\hat{r}$	покр.	$\hat{r}$	покр.	$\hat{r}$	покр.	$\hat{r}$	покр.	$\hat{r}$	покр.	$\hat{r}$
рамка + глубина, L0	0,93	0,75	0,93	0,75	0,93	0,75	0,93	0,85 [†]	0,93	0,85 [†]	0,93	0,85 [†]
рамка + глубина, L4	0,76	0,75	0,97	1,61	0,92	1,23	0,86	0,85 [†]	0,95	2,06 [†]	0,94	1,54 [†]
MobileSAM, L0	0,93	0,75	0,93	0,75	0,93	0,75	0,93	0,61 [†]	0,93	0,61 [†]	0,93	0,61 [†]
MobileSAM, L4	0,78	0,75	0,98	1,61	0,93	1,06	0,80	0,61 [†]	0,93	1,91 [†]	0,95	1,86 [†]
одометрия, каждый 2-й кадр	0,62	0,75	0,96	2,46 [†]	0,96	1,95 [†]	0,74	0,85 [†]	0,99	3,01 [†]	0,96	2,31 [†]
одометрия, каждый 4-й кадр	0,31	0,75	1,00	3,08 [†]	1,00	2,41 [†]	0,65	0,85 [†]	1,00	— [†]	1,00	— [†]
SLAM с замыканиями, каждый 2-й кадр	0,80	0,75	0,95	1,50	0,92	1,59	0,86	0,85 [†]	0,94	2,76 [†]	0,94	2,31 [†]

Одометрия кадр к кадру без замыканий циклов ошибается скачками, в основном на поворотах на месте у стен: АТЕ по сценам от 3,5 см до 3,9 м, медиана 78 см. Запас «только метки» молча теряет покрытие: 0,62 для велосипеда и 0,74 для растения (табл. 9). Совместный запас формально валиден

(0,96) лишь потому, что отказывается в 87 % разбиений; когда сертификат выдан, покрытие 0,71–0,72. В миссиях он не находит ни одного пути: классы переходят на запасной сертификат, а тот при такой ошибке закрывает почти всё. Карта без калибровки находит путь в 23 % трудных задач, и 62 % этих путей опасны. При такой локализации полезной гарантии нет.

SLAM с замыканиями циклов поверх той же одометрии — граф поз Open3D по схеме Choi и др. [31]: ключевой кадр через пять, кандидаты в замыкания по ORB-признакам и PnP по глубине, проверка RGB-D-одометрией и перекрытием облаков, пороги подобраны на отладочной сцене — снижает медианную ATE с 78 до 24 см; ниже 30 см она в 12 сценах из 21 вместо двух. Но в двух сценах замыканий не нашлось (3,3 и 2,0 м), и запас определяют они. «Только метки» для велосипеда даёт 0,80, совместный запас — 0,92 при запасе 1,59 м и без отказов (при одометрии отказ в 86 %); растение по-прежнему отказывается в 63 % разбиений из-за пропуска детектора (табл. 9). В миссиях совместный запас находит путь лишь в 1 % трудных задач, с ансамблем детекторов (разд. 6.5) — в 4 %; карта без калибровки — в 41 %, и 44 % этих путей опасны. Гарантии с реальной локализацией мешает хвост её ошибок, а не медиана: пока среди калибровочных сцен есть сцены без замыканий, запас равен их ошибке. Гарантия на миссии (разд. 6.7) с позами SLAM работает лучше: при $a = 0,05$ успешны 36 % случайных миссий при 0,5 % опасных, при $a = 0,1$ — 12 % трудных; потолок задаёт сама карта, по которой даже без запаса путь находится лишь в 41 % случайных задач.

На сценах HM3D [32] из OSMA-Bench, реальных сканах домов, растение видно с траектории лишь в двух из шести одноэтажных сцен. В одной детектор находит его (промах 0,18 м), в другой делит декоративное растение между тремя чужими классами (2,9 м), и запас с ReplicaCAD его не покрывает — один контрпример, а не оценка. Более мягкий сдвиг, отложенная планировка того же семейства (4 группы по 5 сцен и apt_3), даёт среднее покрытие 0,94–0,96, но для отдельных планировок до 0,80 без дрейфа и 0,63 при 45 см (велосипед в единственной сцене apt_3).

6.11. Качество карты и безопасность

Ранговая корреляция mIoU карты при точных позах с долей опасных путей планировщика без калибровки по 15 сценам $\rho = 0,18$ ($p = 0,53$, 95 %-интервал бутстрепа от $-0,35$ до $0,68$); для IoU одних запретных классов $\rho = -0,07$. Связи не видно, но 15 сцен не позволяют утверждать её отсутствие (H4). mIoU усредняет по клеткам, а безопасность определяет наихудший объект сцены.

7. Обсуждение

Что подтвердилось и что нет. Запас, откалиброванный по одной ошибке, перестаёт работать, когда действует вторая (H1, H2), а совместный запас не больше суммы двух отдельных и при большом дрейфе меньше её на четверть (H3). Связи mIoU с безопасностью на 15 сценах не видно, но и отсутствие её не доказано (H4). Три ожидания не оправдались. Положительная корреляция ошибок делает сумму запасов консервативнее, а недопокрытие возникает, когда редкие сбои локализации и ошибки меток приходятся на разные сцены, и оно невелико. Множества меток выродились не из-за полных пропусков, а из-за обрезанных краёв. Реальная одометрия ошибается не плавно, как модель дрейфа, а скачками.

Отрицательные результаты (получены на предыдущей версии конвейера и не пересчитывались). Выпуклая оболочка и морфологическое замыкание областей не меняют промах: пропущенная часть объекта лежит вне найденного фрагмента, а не в дырах внутри него. Запас, зависящий от уверенности фрагмента, не уменьшил запретную зону.

Главное узкое место — уверенный пропуск или подмена класса целого объекта. Пока калибровочных сцен меньше $2/\alpha - 1$, запас равен наихудшему промаху, и одна такая сцена заставляет класс отказываться в значительной доле разбиений; при 19 сценах растение почти не отказывается. Более сильные детекторы убирают пропуск растения, но у каждого из трёх проверенных находится свой целиком пропущенный класс; подмену тумбы создаёт словарь, а закрытый словарь превращает её в ложные срабатывания. Объединение детекторов по максимуму это узкое место снимает, а проверка находок и голосование возвращают его: гарантия чувствительна к полноте, а не к точности. Метрики качества карты этого не отражают, и в протокол бенчмарков вроде OSMA-Bench естественно добавить долю сцен, где объект пропущен или подменён целиком.

Какую гарантию требовать. Гарантия «каждый объект внутри запаса» дорога, потому что за неё платят и объекты, мимо которых не идёт ни один путь. Гарантия на ожидаемую долю опасных мис-

сий (разд. 6.7) почти не уменьшает число решённых задач, но допускает целиком опасную сцену. Для реальной локализации важен хвост ошибок: SLAM с замыканиями втрое снижает медианную ошибку, но запас задают сцены без замыканий.

Ограничения.

- Одно семейство из 21 симулированной сцены и одно условие освещения. Покрытие на случайных разбиениях одних и тех же сцен выполняется по построению; о поведении на новых сценах говорят лишь бутстреп-интервалы шириной 0,1–0,15, проверка с отложенной планировкой и две сцены HM3D.
- Основной дрейф синтетический и не зависит от ошибок детектора. Реальная локализация проверена одометрией и собственным SLAM с замыканиями на основе Open3D; промышленные системы (ORB-SLAM3, RTAB-Map) не проверялись.
- Восприятие — детектор рамок с масками по глубине или MobileSAM, а не полный картограф.
- Гарантия маргинальна по калибровочным выборкам и покласово; для нескольких классов сразу она слабее, $1 - |\mathcal{K}_m| \alpha$.
- Основная гарантия относится к плану в момент запроса (допущение 1). Исполнение с дрейфом проверено моделью дрейфа, а не реальным роботом; запас на исполнение калибруется по объединённой выборке путей, и его обменяемость приближённая. Столкновения с препятствиями не покрываются. Дискретизация может съесть до 7 см безопасного расстояния.
- Семейство трудных задач и пара запретных классов для миссий выбраны после первых прогонов; множества меток реализованы нами на итоговой карте, без режима исследования авторов.

8. Заключение

Расстояние промаха в системе координат планировщика — одна калибруемая величина, которая даёт планировщику гарантию сразу против ошибки метки и ошибки позы и честно отказывается, когда гарантия была бы бесполезной. Запасы по одной ошибке теряют покрытие под действием другой, сумма отдельных запасов переплачивает или недопокрывает в зависимости от неизвестного расположения сбоев, а калибровка множеств меток вырождается в запрет всего занятого. Цену гарантии задаёт наихудшая ошибка восприятия или локализации среди калибровочных сцен. Её снижают объединение детекторов (полнота важнее точности) и переход к гарантии на долю опасных миссий; исполнение с дрейфом до 7 см гарантию не ломает. Следующие шаги — больше калибровочных сцен (например, данные OSMa-Bench++), SLAM, находящий замыкания во всех сценах, перелокализация во время движения и полный открытословарный картограф вместо детектора рамок.

Список литературы

- [1] ConceptGraphs: Open-Vocabulary 3D Scene Graphs for Perception and Planning / Q. Gu [и др.] // 2024 IEEE International Conference on Robotics and Automation (ICRA). — 2024. — P. 5021–5028. — DOI 10.1109/ICRA57147.2024.10610243.
- [2] OSMa-Bench: Evaluating Open Semantic Mapping Under Varying Lighting Conditions / M. Popov [и др.] // 2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). — 2025. — P. 10786–10791. — DOI 10.1109/IROS60139.2025.11247603.
- [3] 3D Scene Graphs: Open Challenges and Future Directions / D. Rotondi [и др.] // arXiv preprint. — 2026. — arXiv:2606.19383. — (Приглашённая статья для Annual Review of Control, Robotics, and Autonomous Systems, т. 10, по комментарию arXiv.)
- [4] Angelopoulos A. N. A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification / A. N. Angelopoulos, S. Bates // arXiv preprint. — 2021. — arXiv:2107.07511.
- [5] Safe Planning in Unknown Environments Using Conformalized Semantic Maps / D. S. Sundarsingh [и др.] // IEEE Robotics and Automation Letters. — 2026. — Vol. 11, no. 4. — P. 4921–4928. — DOI 10.1109/LRA.2026.3668466.
- [6] Perceive With Confidence: Statistical Safety Assurances for Navigation with Learning-Based Perception / Z. Mei [и др.] // The International Journal of Robotics Research. — 2025. — Vol. 45, no. 6. — P. 938–967. — DOI 10.1177/02783649251378151.
- [7] Baral R. Marginal Calibration Does Not Compose: Hidden Dependence in Modular Robot Navigation / R. Baral // arXiv preprint. — 2026. — arXiv:2609.23731. — (Воркшоп «Rethinking Uncertainty for Modern Robotics Paradigms», IROS 2026.)
- [8] Kurkova R. OSMa-Bench++: Toward Open-Ended Benchmarking of Semantic Mapping for Manipulation with Prompt-Generated Synthetic Scenes / R. Kurkova, M. Popov, S. Kolyubin // arXiv preprint. — 2026. — arXiv:2605.26831. — (Воркшоп ICRA 2026 «Open Challenges for Rigorous Robot Perception».)

- [9] Correia Marques J. M. On the Overconfidence Problem in Semantic 3D Mapping / J. M. Correia Marques, A. Zhai, S. Wang, K. Hauser // 2024 IEEE International Conference on Robotics and Automation (ICRA). — 2024. — P. 11095–11102. — DOI 10.1109/ICRA57147.2024.10611306.
- [10] Tchuiev V. Epistemic uncertainty aware semantic localization and mapping for inference and belief space planning / V. Tchuiev, V. Indelman // Artificial Intelligence. — 2023. — Vol. 319. — P. 103903. — DOI 10.1016/j.artint.2023.103903.
- [11] Safe Planning in Dynamic Environments using Conformal Prediction / L. Lindemann [и др.] // IEEE Robotics and Automation Letters. — 2023. — Vol. 8, no. 8. — P. 5116–5123. — DOI 10.1109/LRA.2023.3292071.
- [12] Safe Perception-Based Control Under Stochastic Sensor Uncertainty Using Conformal Prediction / S. Yang, G. J. Pappas, R. Mangharam, L. Lindemann // 2023 62nd IEEE Conference on Decision and Control (CDC). — 2023. — P. 6072–6078. — DOI 10.1109/CDC49753.2023.10384075.
- [13] Shin J. From Prediction Uncertainty to Conformalized Distance Fields for Safe Motion Planning / J. Shin, Y. Ra, I. Yang // arXiv preprint. — 2026. — arXiv:2607.00776.
- [14] Kim E. M. SCORE: Shape-Conforming Regions for Flight in Enclosed, Degraded Environments / E. M. Kim, J.-K. Kim // arXiv preprint. — 2026. — arXiv:2608.15289.
- [15] Learnable Conformal Prediction with Context-Aware Nonconformity Functions for Robotic Planning and Perception / D. Kumar [и др.] // 2026 IEEE International Conference on Robotics and Automation (ICRA). — 2026. — arXiv:2509.21955. — (Сверка версии в трудах ICRA с arXiv не проводилась.)
- [16] Natraj S. Conformal Constraint Tightening for Chance-Constrained Motion Planning with Unknown Dynamics / S. Natraj, B. Sinopoli, Y. Kantaros // arXiv preprint. — 2026. — arXiv:2607.22409.
- [17] Calafiore G. C. Bridging Conformal Prediction and Scenario Optimization: Discarded Constraints and Modular Risk Allocation / G. C. Calafiore // arXiv preprint. — 2026. — arXiv:2603.19396.
- [18] Mahajan R. Finite-Sample Conformal Coverage Recovery via Fusion under Degraded Local Guarantees in Occupancy Map Estimation / R. Mahajan, A. Raghavan, K. H. Johansson // arXiv preprint. — 2026. — arXiv:2607.14906.
- [19] Conformal prediction beyond exchangeability / R. F. Barber, E. J. Candès, A. Ramdas, R. J. Tibshirani // The Annals of Statistics. — 2023. — Vol. 51, no. 2. — DOI 10.1214/23-AOS2276.
- [20] P-POSEMEM: Projective Semantic Memory for Consistent Language Grounding under Pose-Graph Rewrites / H. Sier [и др.] // arXiv preprint. — 2026. — arXiv:2609.15475.
- [21] Habitat 2.0: Training Home Assistants to Rearrange their Habitat / A. Szot [и др.] // Advances in Neural Information Processing Systems (NeurIPS). — 2021. — arXiv:2106.14405.
- [22] YOLO-World: Real-Time Open-Vocabulary Object Detection / T. Cheng [и др.] // 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2024. — P. 16901–16911. — DOI 10.1109/CVPR52733.2024.01599.
- [23] Zhou Q.-Y. Open3D: A Modern Library for 3D Data Processing / Q.-Y. Zhou, J. Park, V. Koltun // arXiv preprint. — 2018. — arXiv:1801.09847.
- [24] Steinbrücker F. Real-time visual odometry from dense RGB-D images / F. Steinbrücker, J. Sturm, D. Cremers // 2011 IEEE International Conference on Computer Vision Workshops (ICCV Workshops). — 2011. — P. 719–722. — DOI 10.1109/ICCVW.2011.6130321.
- [25] Faster Segment Anything: Towards Lightweight SAM for Mobile Applications / C. Zhang, D. Han, Y. Qiao [и др.] // arXiv preprint. — 2023. — arXiv:2306.14289.
- [26] YOLOE: Real-Time Seeing Anything / A. Wang, L. Liu, H. Chen [и др.] // 2025 IEEE/CVF International Conference on Computer Vision (ICCV). — 2025. — P. 24591–24602. — DOI 10.1109/ICCV51701.2025.02280.
- [27] Learning Transferable Visual Models From Natural Language Supervision / A. Radford, J. W. Kim, C. Hallacy [и др.] // International Conference on Machine Learning (ICML), PMLR. — 2021. — Vol. 139. — P. 8748–8763. — arXiv:2103.00020.
- [28] Lee Y. Distribution-free inference with hierarchical data / Y. Lee, R. F. Barber, R. Willett // ACM Journal of Data Science. — 2026. — DOI 10.1145/3786352. — arXiv:2306.06342.
- [29] Vovk V. Conditional validity of inductive conformal predictors / V. Vovk // Machine Learning. — 2013. — Vol. 92, no. 2–3. — P. 349–376. — DOI 10.1007/s10994-013-5355-6.
- [30] Conformal Risk Control / A. N. Angelopoulos, S. Bates, A. Fisch [и др.] // International Conference on Learning Representations (ICLR). — 2024. — arXiv:2208.02814.

- [31] Choi S. Robust reconstruction of indoor scenes / S. Choi, Q.-Y. Zhou, V. Koltun // 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2015. — P. 5556–5565. — DOI 10.1109/CVPR.2015.7299195.
- [32] Habitat-Matterport 3D Dataset (HM3D): 1000 Large-scale 3D Environments for Embodied AI / S. K. Ramakrishnan, A. Gokaslan, E. Wijmans [и др.] // NeurIPS Datasets and Benchmarks. — 2021. — arXiv:2109.08238.